Derin Öğrenme

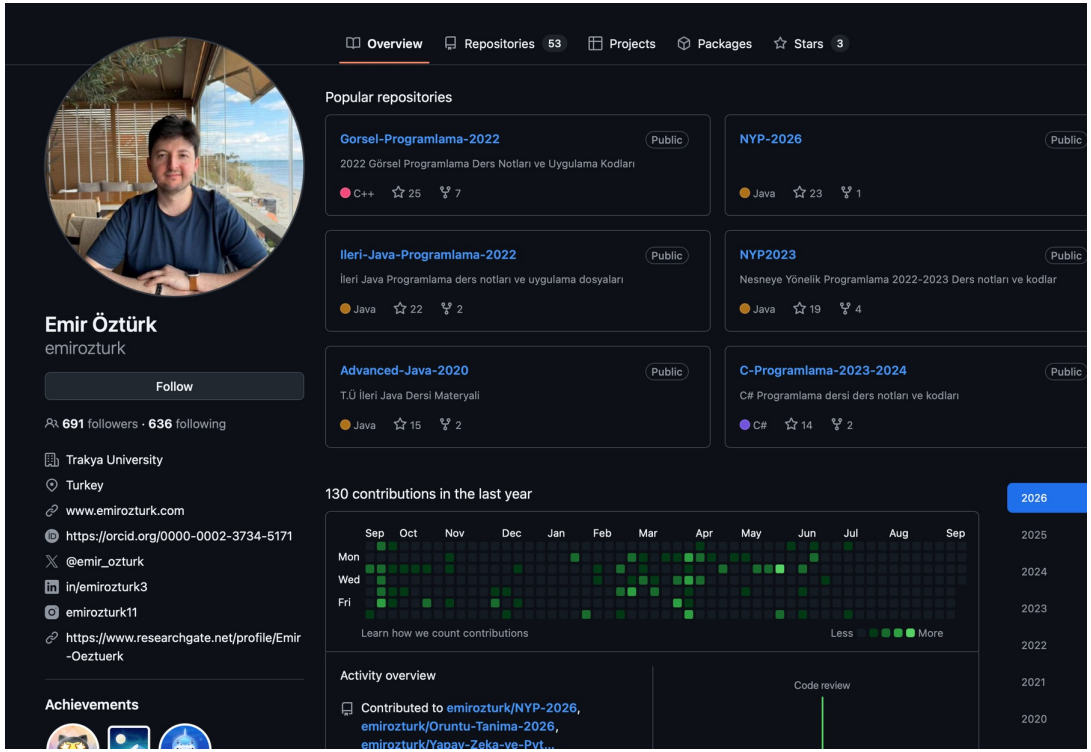
Derin Öğrenmeye Giriş

Hafta 1

Doç. Dr. Emir Öztürk
Trakya Üniversitesi · Bilgisayar Mühendisliği

Tanışma

- Çalışma alanları
  - Veri sıkıştırma
  - Bilgi güvenliği
  - Makine öğrenmesi
  - Derin öğrenme
- Ders materyalleri ve kodlar GitHub üzerinden paylaşılır
- @emirozturk



Çalışma konuları

Görüntü sıkıştırma yöntemlerinin etkinliğini arttıran dönüşüm ve bölümlendirme işlemleri (2012)

Exam Scheduling With Genetic Algorithms (2012)

File size estimation in JPEG XR standard using machine learning (2016)

Finding The Optimal Lossless Compression Method For Images Using Machine Learning Algorithms (2016)

Entropy Based Estimation Algorithm Using Split Images to Increase Compression Ratio (2017)

Derin Öğrenme Kullanılarak Optimum JPEG Kalite Faktörünün Belirlenmesi (2020)

Kısa Metinlerin Sıkıştırılması için BERT Tabanlı bir Yöntem (2021)

XCompress: LLM assisted Python-based text compression toolkit (2024)

Comparison of Learned Image Compression Methods and JPEG (2024)

A character based steganography using masked language modeling (2024)

Identifying Image Compression Methods Using Vision Transformers (2024)

Performance Analysis of Chroma, Qdrant And Faiss Databases (2024)

Introduction to Retrieval Augmented Generation (RAG) - PyData Türkiye 2024

Resim Dosyalarında LSB Yöntemi ile Gizlenen Steganografik Verilerin Görsel Dil Modelleri Kullanarak Tespit Edilmesi (2024)

Dersin işleyişi

- Hafta 13–14: öğrenci makale sunumları

Hafta	Konu	Hafta	Konu
1	Giriş	7	Üretken modeller ve difüzyon
2	Derin öğrenmenin temelleri	8	Öz-denetimli ve çok modlu öğrenme
3	Evrişimli sinir ağları	9	Derin pekiştirmeli öğrenme
4	Diziler ve RNN	10	Graf öğrenme ve meta öğrenme
5	NLP ve Transformer	11	Açıklanabilirlik, sağlamlık, verimlilik
6	Büyük dil modelleri	12	Güncel mimariler ve yönelimler

Zekâ nedir?

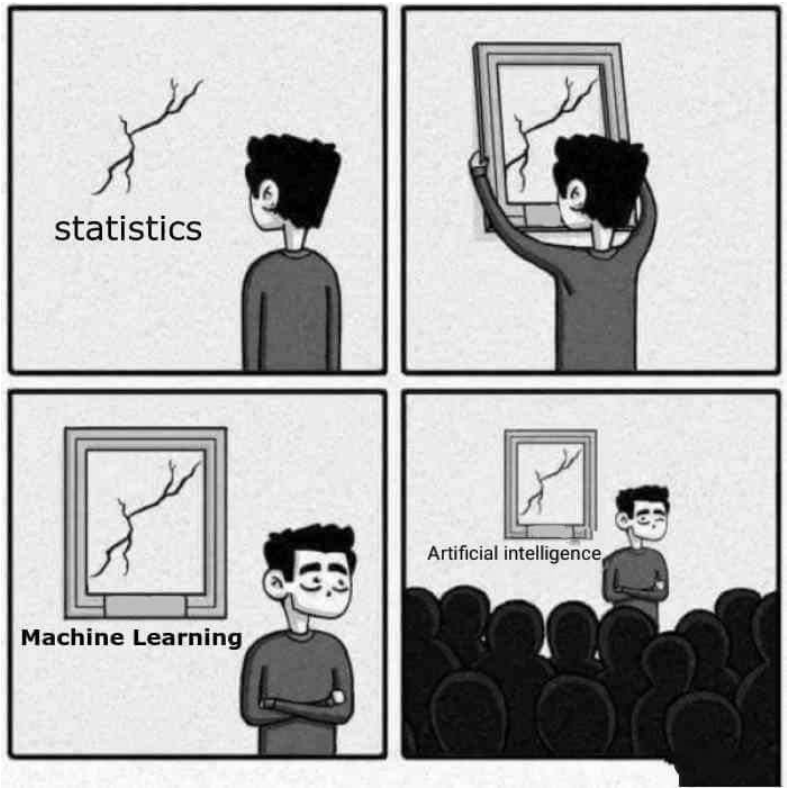
- Bir işi yapabilmek
- Bir işi çok iyi yapabilmek
- Birçok işi yapabilmek
- Birçok işi çok iyi yapabilmek
- Zekânın biçimsel tanımı
  - Ortamlar üzerinden ağırlıklı başarı

$$\underbrace{\Upsilon(\pi)}_{\text{Measure of Intelligence}} := \sum_{\underbrace{\mu \in E}_{\text{Sum over environments}}} \underbrace{2^{-K(\mu)}}_{\text{Complexity penalty}} \underbrace{V_\mu^\pi}_{\text{Value achieved}}.$$

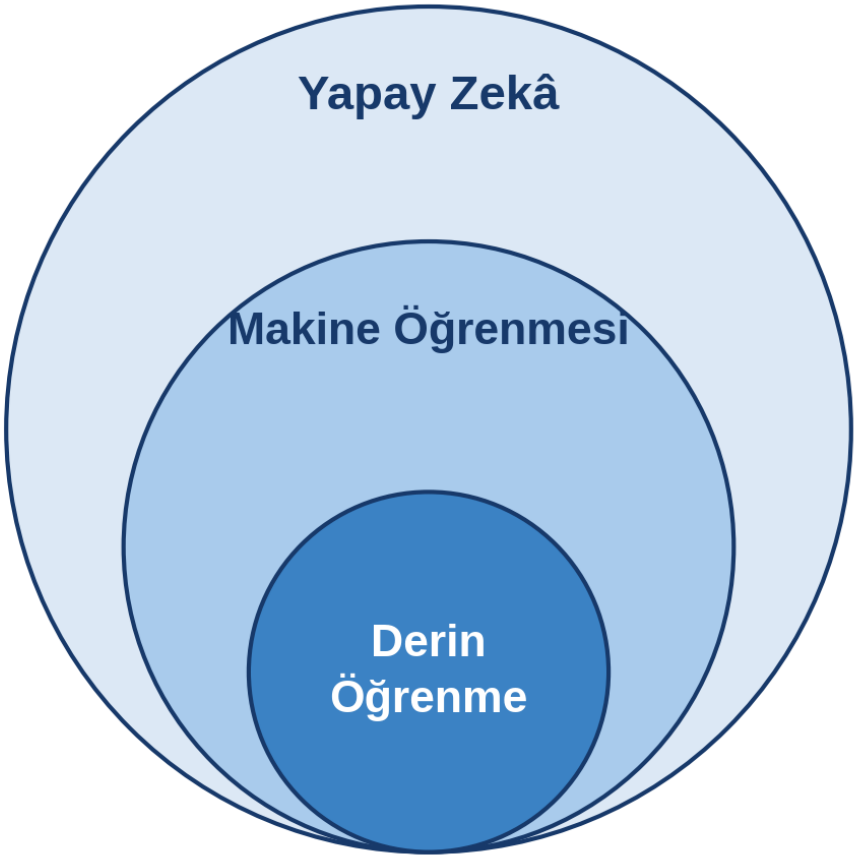
Legg, S., Hutter, M. (2007). Universal intelligence: A definition of machine intelligence. Minds and Machines, 17(4), 391–444.

Yapay zekâ nedir?

- Popüler kavram zinciri
  - Büyük veri → Blokzincir → Yapay zekâ
- Yapay zekâ ⊃ Makine öğrenmesi ⊃ Derin öğrenme
- Zekânın hesaplamalı simülasyonu
- Soru: sistem ne yapıyor, nasıl yapıyor?



Makine öğrenmesi – Derin öğrenme



Yapay zekâ

İnsan zekâsı gerektiren görevleri yerine getiren sistemler (arama, planlama, kural tabanlı sistemler)

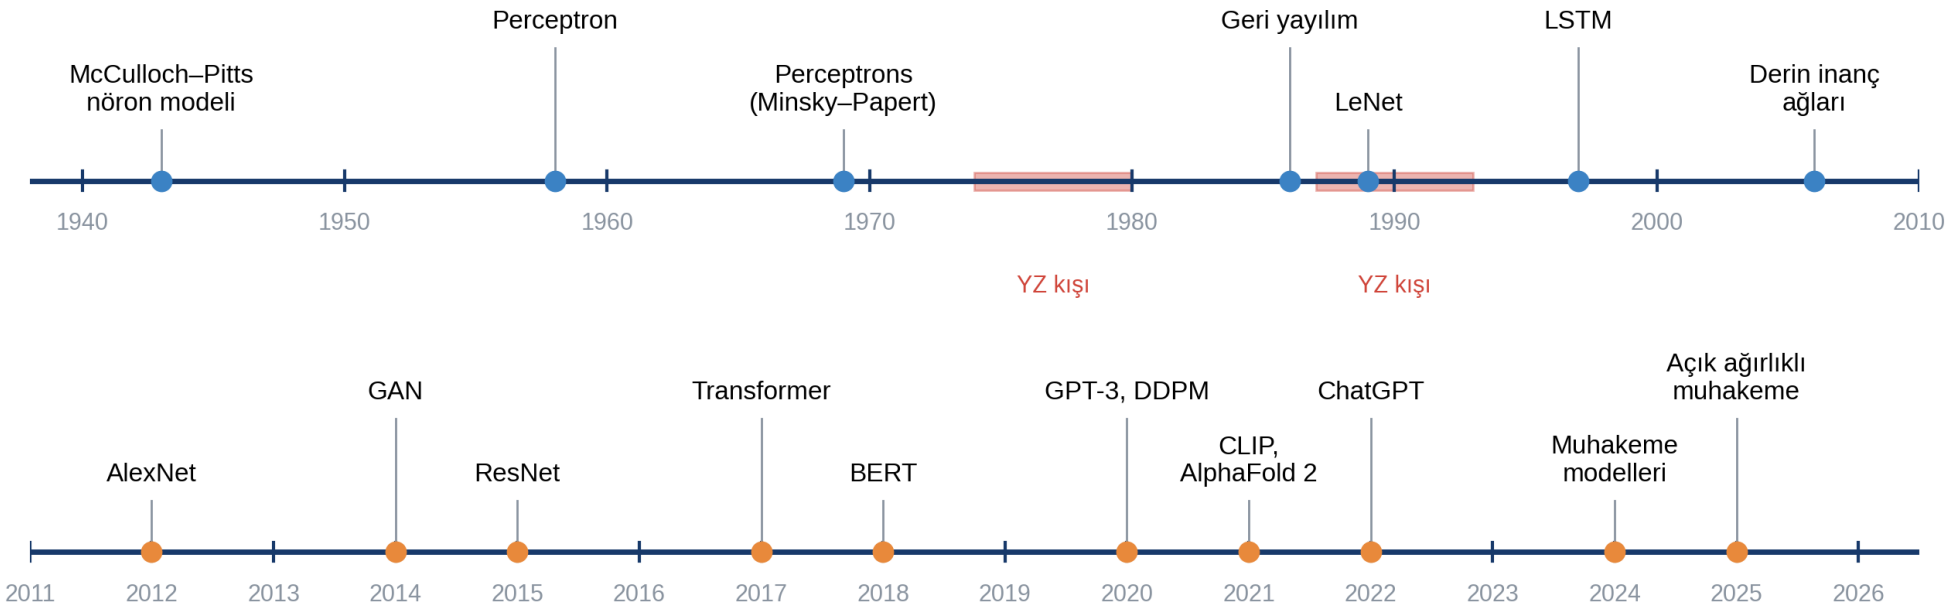
Makine öğrenmesi

Davranışı açıkça programlanmak yerine veriden öğrenen yöntemler (karar ağacı, SVM, k-NN)

Derin öğrenme

Çok katmanlı yapay sinir ağlarıyla temsilin kendisini de veriden öğrenen yöntemler

Kısa tarihçe



Makine öğrenmesi

- Algoritmanın girdisi: özellikler (öznitelikler)
- Özelliklerin probleme göre seçilmesi gerekir
- Özellik belirleme öznel bir süreçtir
- Veri yapısı bilinmediğinde yanlış özellik seçme riski
- Birbiriyle ilişkili özellikler bilgi katmaz, gürültü ekler

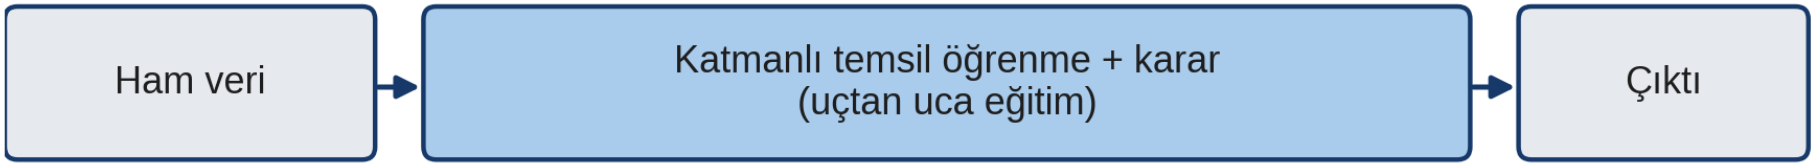
Özellik mühendisliğinden temsil öğrenmeye

Klasik makine öğrenmesi



uzman bilgisi gerekir

Derin öğrenme



Derin öğrenme nedir?

- Makine öğrenmesinin bir alt dalı
- Çok katmanlı yapay sinir ağları
- Büyük veri setleri ile eğitim



Makine öğrenmesinin bir alt dalıdır



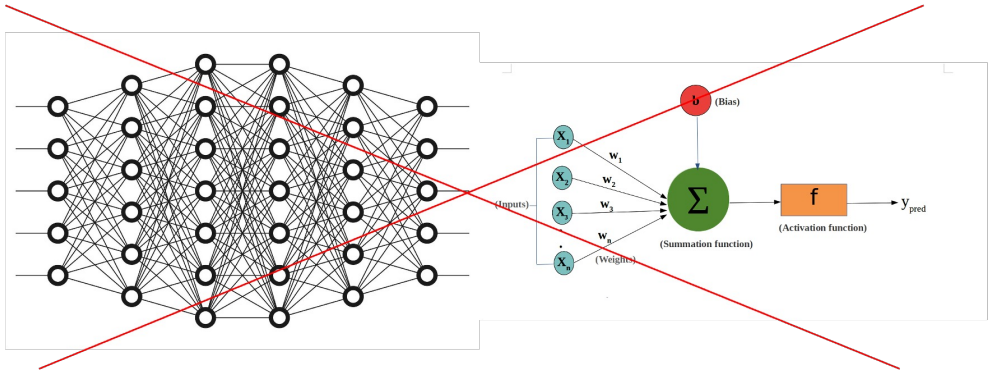
Yapay sinir ağları



Büyük veri setleri

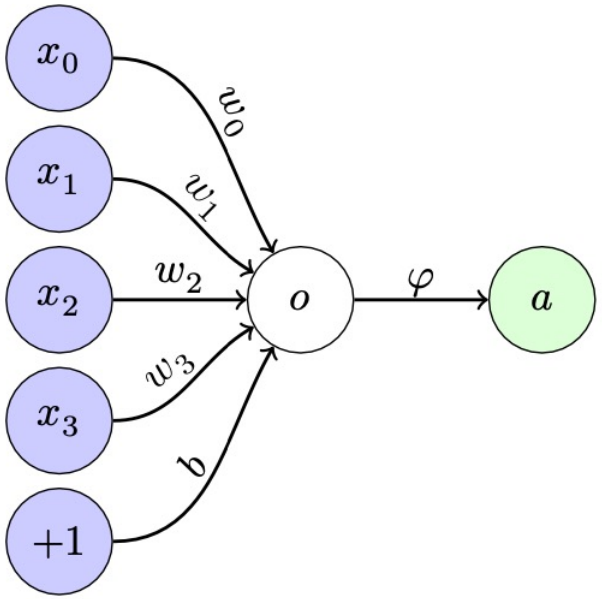
Derin öğrenme ne değildir?

- Her problemin çözümü değildir
- Tablo verisinde ağaç tabanlı yöntemler çoğu zaman daha başarılı
- Bir nöronun biyolojik nöronun birebir modeli değildir
- Ağırlıkların anlamı doğrudan okunamaz

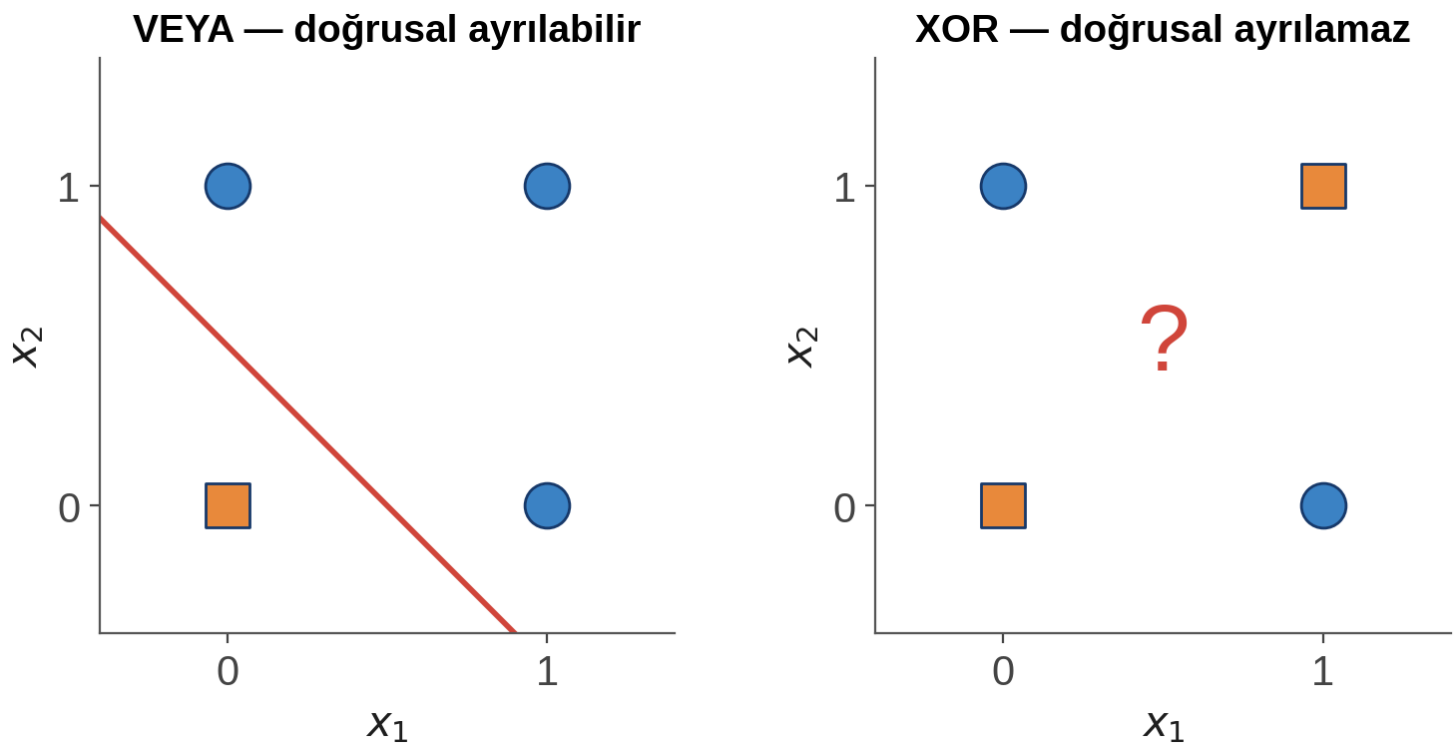


Perceptron

- Rosenblatt (1958)
- Ağırlıklı toplam + eşik fonksiyonu
  - a = ϕ(w·x + b)
- Tek katman: yalnız doğrusal ayrılabilir problemler
- XOR problemi (Minsky ve Papert, 1969)

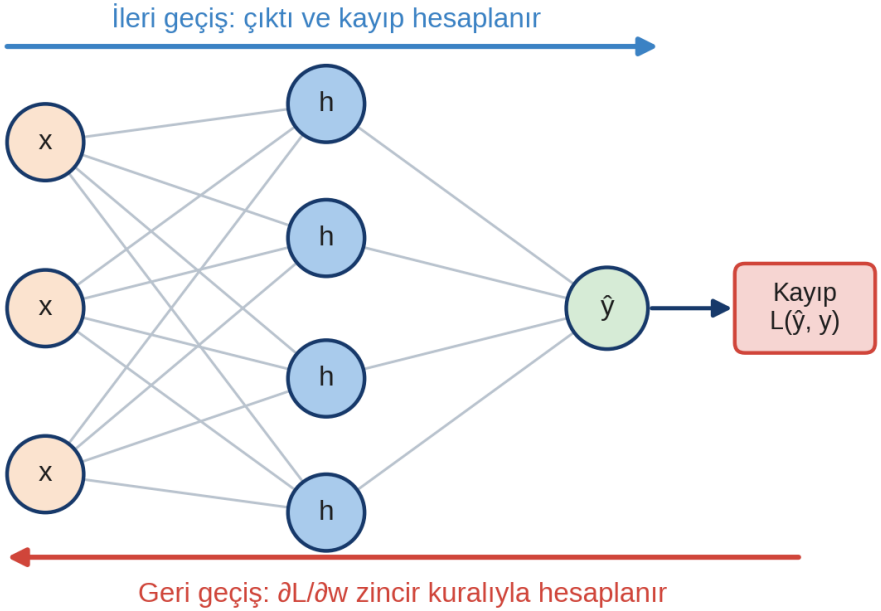


Doğrusal ayrılabilirlik



Geri yayılım (backpropagation)

- İleri geçiş: tahmin ve kayıp hesabı
- Geri geçiş: kaybın her ağırlığa göre türevi
  - Zincir kuralı
- Ağırlık güncellemesi: $w \leftarrow w - \eta \, \partial L/\partial w$



Derin öğrenmenin bileşenleri

- Özellik seçiminde daha az işlenmiş veri
- Yapının ayrıntılarını elle tanımlamaya gerek yok
- Gereken temel yapı
  - Veri
  - Model (mimari)
  - Kayıp fonksiyonu
  - Optimizasyon yöntemi
  - Değerlendirme ölçütü

Neden şimdi yaygınlaştı?

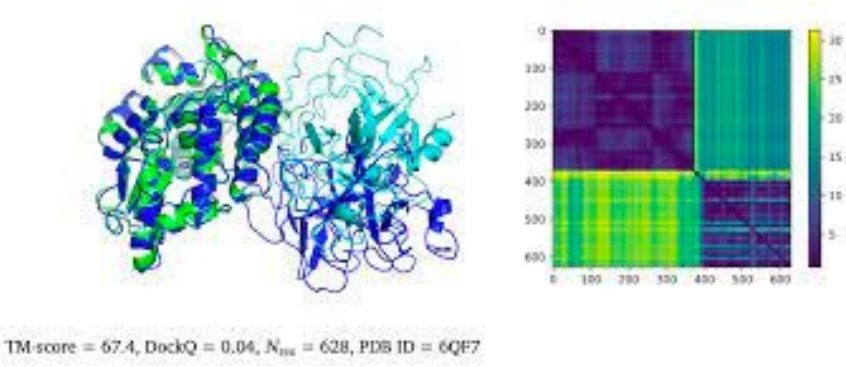
- Hesaplama gücü
  - GPU, TPU, NPU
- Veri miktarındaki artış
- Açık kaynak kütüphaneler
  - PyTorch, JAX, TensorFlow, MLX
- Ortak veri setleri ve karşılaştırma ölçütleri
- Önceden eğitilmiş modellerin paylaşılması

Derin öğrenmenin sınırları

- Arama uzayı hâlâ sınırlı tutulmak zorunda
- Çok büyük uzaylarda sadeleştirme gerekir
- Örnek
  - Satranç: ~10^{120} olası oyun (Shannon)
  - Go: ~10^{170} geçerli konum
- AlphaGo: arama + öğrenilmiş değer ve politika ağları

Uzay küçültme

- Bazı problemler doğrudan öğrenme için fazla karmaşık
- Boyutun probleme özgü yollarla küçültülmesi
  - 3B yapı → 2B mesafe haritası
- AlphaFold 2 (2021)
  - Protein yapısı tahmini
  - 2024 Nobel Kimya Ödülü



TM-score = 67.4, DockQ = 0.04, N_{res} = 628, PDB ID = 6QF7

Temel mimari aileleri

Evrişimli Sinir Ağları (CNN)
Hafta 3

LeNet, AlexNet, VGG, ResNet,
EfficientNet, YOLO

Tekrarlayan Sinir Ağları (RNN)
Hafta 4

Vanilla RNN, LSTM, GRU,
Seq2Seq

Transformer ve LLM
Hafta 5–6

BERT, GPT, T5, ViT,
büyük dil modelleri

Üretken modeller
Hafta 7

Autoencoder, VAE, GAN,
difüzyon modelleri

Pekiştirmeli öğrenme
Hafta 9

DQN, policy gradient,
PPO, RLHF

Graf sinir ağları
Hafta 10

GCN, GraphSAGE, GAT,
mesaj iletimi

Güncel konular

Öğrenme biçimleri	Model aileleri	Güvenilirlik ve verim
Öz-denetimli öğrenme	Difüzyon modelleri	Açıklanabilir YZ
Az / sıfır örnekli öğrenme	Çok modlu modeller (CLIP, VLM)	Çekişmeli sağlamlık
Meta öğrenme	Graf sinir ağları	Nicemleme, budama, damıtma
Federe öğrenme	Durum uzayı modelleri (Mamba)	YZ etiği ve düzenlemeler

Model eğitim aşamaları – Veri eldesi

- Veri kaynakları
  - huggingface.co/datasets
  - kaggle.com/datasets
  - datasetsearch.research.google.com
  - archive.ics.uci.edu
  - dumps.wikimedia.org
  - commoncrawl.org



Model eğitim aşamaları – Önişleme

Veri temizleme	Veri dönüşümü	Veri kodlama	Veri artırma
Eksik değerler	Normalizasyon	Etiket kodlama	Görüntü dönüşümleri
Aykırı değerler	Standartlaştırma	One-hot kodlama	Metin artırma
Yinelenen kayıtlar	Logaritmik dönüşüm	Gömme (embedding)	Sentetik veri

Veri bölme



model seçimi
yalnız doğrulamada

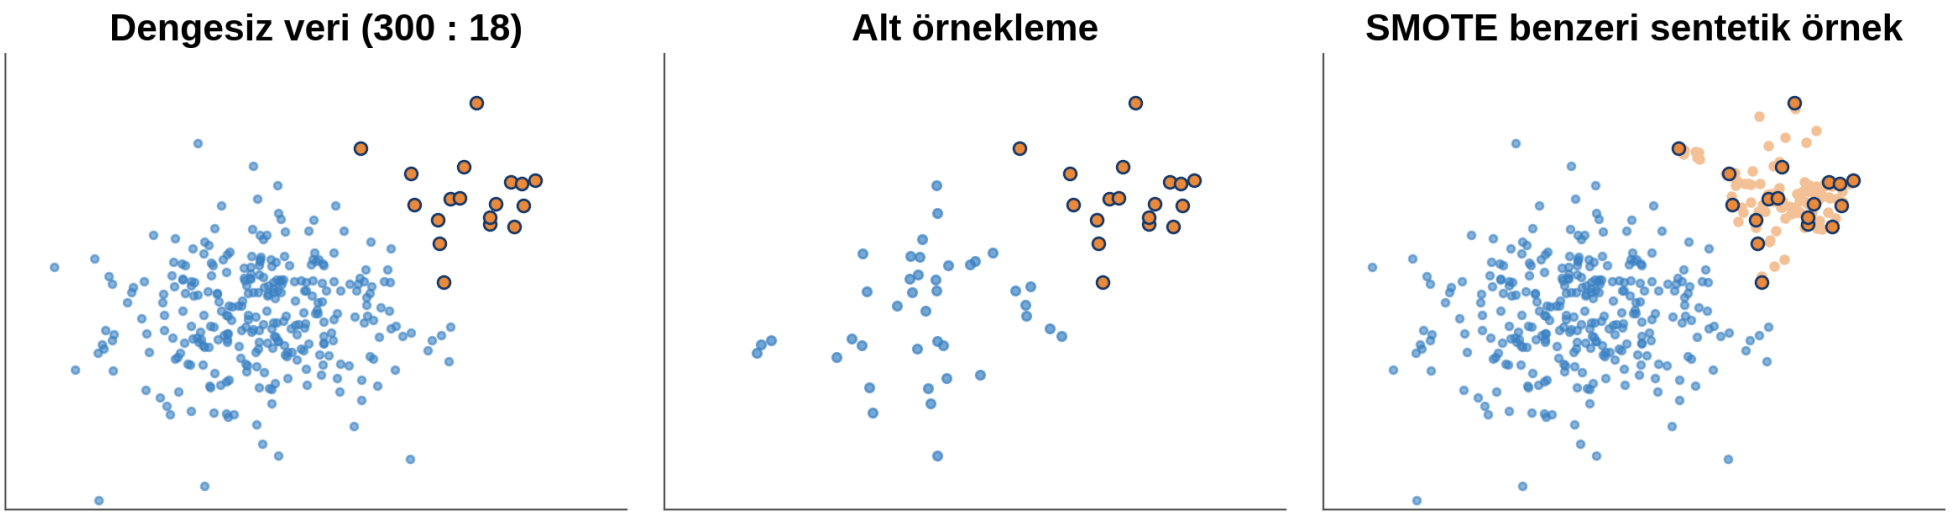
k-katlı çapraz doğrulama (k = 5)



Her katman bir kez doğrulama olarak kullanılır;
başarı k çalıştırmanın ortalamasıdır.

Dengesiz veri

- Bir sınıfın örnek sayısı diğerlerinden çok az
- Doğruluk yanıltıcı olur
- Çözümler
  - Alt örnekleme / aşırı örnekleme
  - Sentetik örnek (SMOTE)
  - Kayıp fonksiyonunda sınıf ağırlığı



Öğrenme paradigmaları

Denetimli	Denetimsiz	Öz-denetimli	Pekiştirmeli
(x, y) çiftleri hedef: f(x) ≈ y	yalnız x hedef: yapıyı bulmak	x içinden üretilen sözde etiketler	durum, eylem, ödül hedef: toplam ödül

Denetimli – Denetimsiz öğrenme

- Denetimli öğrenme
  - Girdi ve istenen çıktı birlikte verilir
  - Sınıflandırma, regresyon
- Denetimsiz öğrenme
  - Etiket gereksinimi yok
  - Kümeleme, boyut indirgeme, yoğunluk kestirimi
- Öz-denetimli öğrenme
  - Etiket verinin kendisinden üretilir
  - Büyük dil modellerinin ön eğitimi

Az örnekli ve sıfır örnekli öğrenme

- Tek örnekli (one-shot) öğrenme
  - Her sınıftan yalnız bir örnek
- Az örnekli (few-shot) öğrenme
  - Her sınıftan birkaç örnek
- Sıfır örnekli (zero-shot) öğrenme
  - Eğitimde görülmeyen sınıflar
  - Sınıfın metinsel tanımı üzerinden eşleme

Pekiştirmeli öğrenme

- Ajan
- Ortam durumu
- Eylem
- Etkileşim
- Ödül ve başarı ölçümü
- Derin pekiştirmeli öğrenme

Sıfırdan eğitim – İnce ayar

- Sıfırdan eğitim
  - Yüksek hesaplama kaynağı
  - Uzun eğitim süresi
  - Büyük veri gereksinimi
  - Başarı oranı veri miktarına bağlı
- İnce ayar (fine-tuning)
  - Önceden eğitilmiş ağırlıklardan başlanır
  - PEFT (parametre verimli ince ayar)
  - LoRA (düşük ranklı uyarlama)

Geliştirme ortamı

- Python + PyTorch
- Alternatifler: JAX, TensorFlow/Keras, MLX
- Jupyter, Google Colab, Kaggle Notebooks
- Hugging Face: modeller ve veri setleri

```
import torch, torch.nn as nn

model = nn.Sequential(nn.Linear(2, 8), nn.ReLU(), nn.Linear(8, 1))
X = torch.tensor([[0., 0.], [0., 1.], [1., 0.], [1., 1.]])
y = torch.tensor([[0.], [1.], [1.], [0.]])          # XOR
opt = torch.optim.Adam(model.parameters(), lr=0.05)
for epoch in range(500):
    loss = nn.functional.binary_cross_entropy_with_logits(model(X), y)
    opt.zero_grad(); loss.backward(); opt.step()
print(torch.sigmoid(model(X)).round())
```