Derin Öğrenme

Derin Öğrenmenin Temelleri

Hafta 2

Doç. Dr. Emir Öztürk
Trakya Üniversitesi · Bilgisayar Mühendisliği

Yapay sinir ağlarının öncülleri

- Derin öğrenme öncesinde yaygın modeller
  - Hopfield ağları (1982)
  - Öz-örgütlemeli haritalar (SOM, 1982)
  - Kısıtlı Boltzmann makineleri (RBM)
  - Derin inanç ağları (DBN, 2006)
- Katman katman denetimsiz ön eğitim
- Günümüzde yerini uçtan uca eğitime bırakmıştır

Derin öğrenmenin uygulama alanları

- Bilgisayarlı görü
- Doğal dil işleme
- Ses işleme
- Kontrol ve otonom sistemler
- Üretken yapay zekâ
- Çok modlu sistemler
- Otonom YZ ajanları
- Bilimsel hesaplama (protein, malzeme, hava tahmini)

Derin öğrenmenin yaygınlaşması

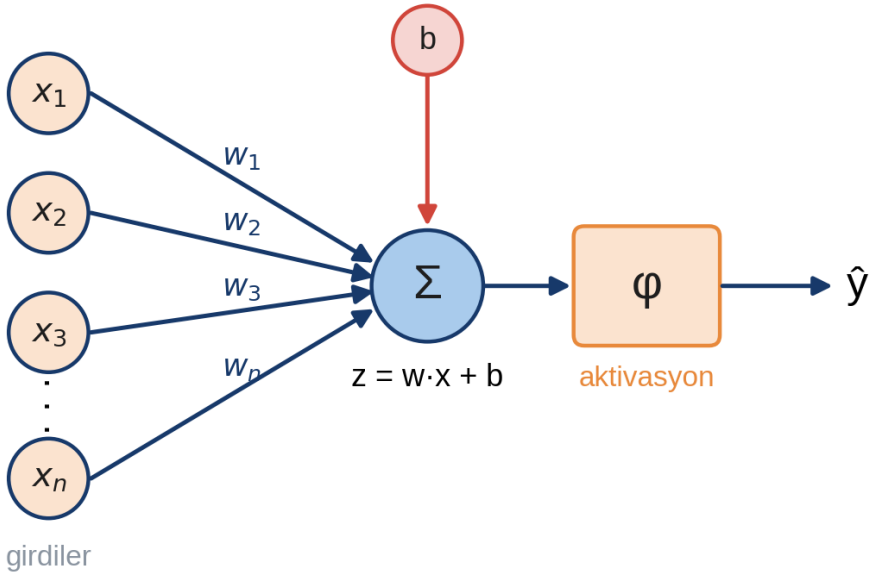
- Veri
  - Sentetik veri
- Hesaplama gücü
- Modülerlik: katmanlar birleştirilerek model kurulur
- Öğrenme eğrisi düşük
  - Hızlı model üretme
  - Hızlı ama **yanlış** model üretme riski
- Hazır araçlar (scikit-learn, WEKA, Hugging Face)

Derin öğrenme başarısı

- Daha çok veri ≠ daha yüksek başarı
- Daha büyük model ≠ daha yüksek başarı
- Daha ham veri ≠ daha yüksek başarı
- Belirleyici olanlar
  - Veri kalitesi ve temsil gücü
  - Problem ile uyumlu mimari
  - Doğru kurulmuş değerlendirme

Yapay nöron

- Biyolojik nörondan esinlenmiş basit model
- Girdilerin ağırlıklı toplamı: z = w·x + b
- Sapma (bias) terimi b
- Aktivasyon fonksiyonu: ŷ = ϕ(z)



Yapay sinir ağları – bir örnek

- Ders geçme durumu: vize ve final notları
- Başarı notu = 0,3 · vize + 0,7 · final

Vize	Final	Başarı notu	Geçiyor mu?
50	50	50,0	1
30	70	58,0	1
70	30	42,0	0
37	43	41,2	0
85	76	78,7	1
100	28	49,6	1
42	100	82,6	1

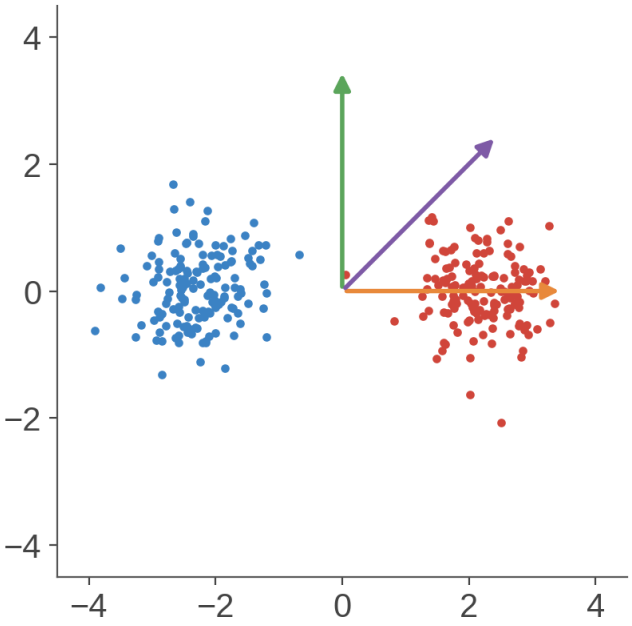
Ağırlıkların denenmesi

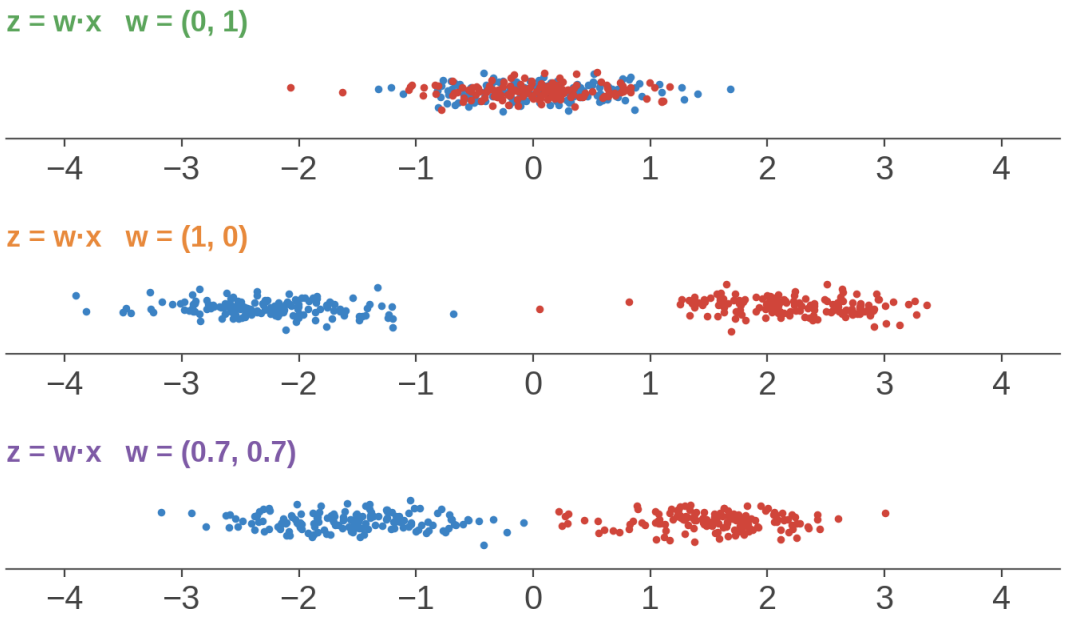
- Tahmin: w_v · vize + w_f · final ≥ 49,5 ise 1

Vize	Final	Gerçek	W_1 (0,5; 0,5)	W_2 (0,6; 0,4)	W_3 (0,8; 0,2)	W_4 (0,3; 0,7)
50	50	1	1	1	1	1
30	70	1	1	0	0	1
70	30	0	1	1	1	0
37	43	0	0	0	0	0
85	76	1	1	1	1	1
100	28	1	1	1	1	1
42	100	1	1	1	1	1
		Doğruluk	**0,86**	**0,71**	**0,71**	**1,00**

Bir nöron ve çıktısı

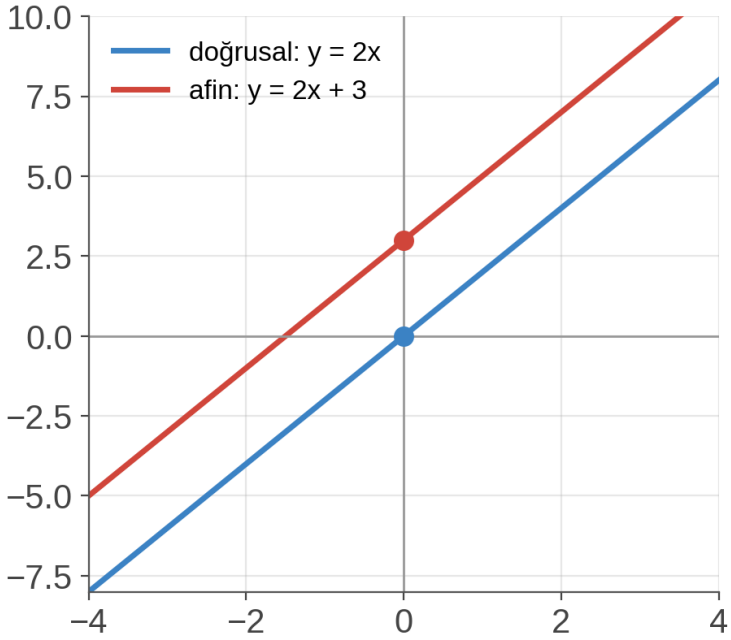
- z = w·x + b: tek başına doğrusal regresyon
- w·x: girdinin w yönüne izdüşümü
- Farklı w → farklı ayrılabilirlik





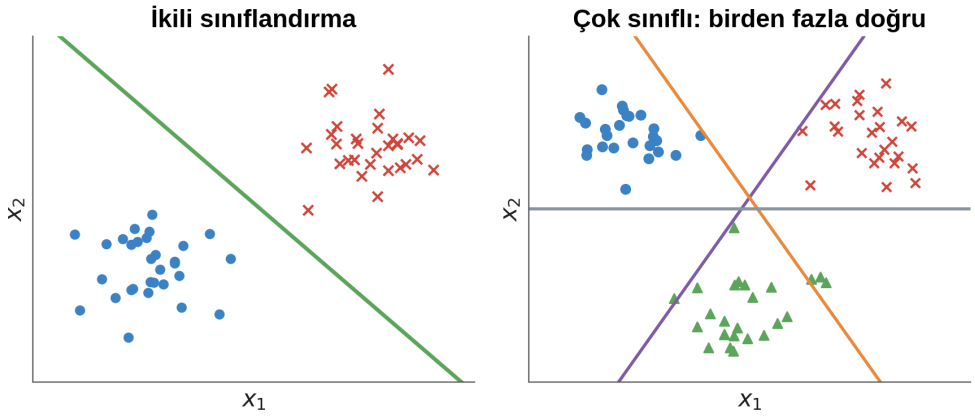
Doğrusal katman

- "Doğrusal" katman aslında afin bir dönüşümdür
  - Doğrusal: y = Wx
  - Öteleme: + b
  - Afin: y = Wx + b
- Her doğrusal fonksiyon afindir
- Her afin fonksiyon doğrusal değildir
  - f(0) = b ≠ 0

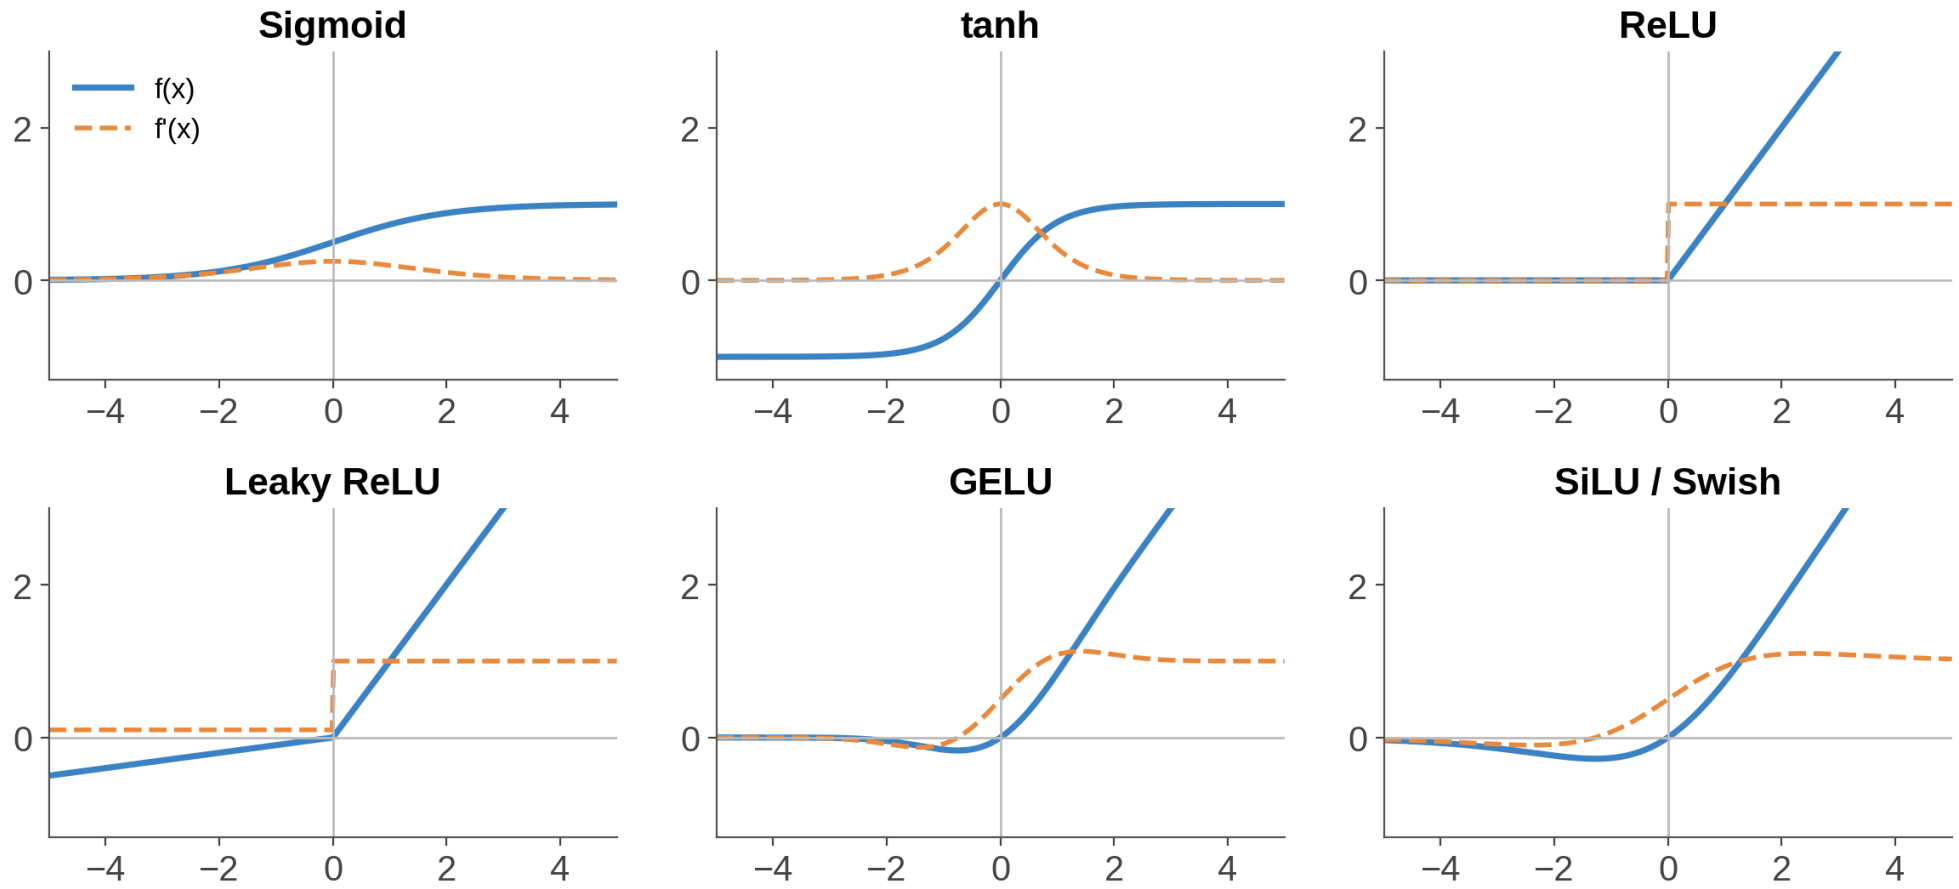


Karmaşık problemlerin çözümü

- Tek bir doğru yetersiz
- Doğrusal katmanları art arda eklemek yetmez
  - $W_2(W_1x + b_1) + b_2 = W'x + b'$
- Katmanlar arasına doğrusal olmayan fonksiyon
- Çok sınıflı problemlerde birden fazla karar sınırı



Aktivasyon fonksiyonları

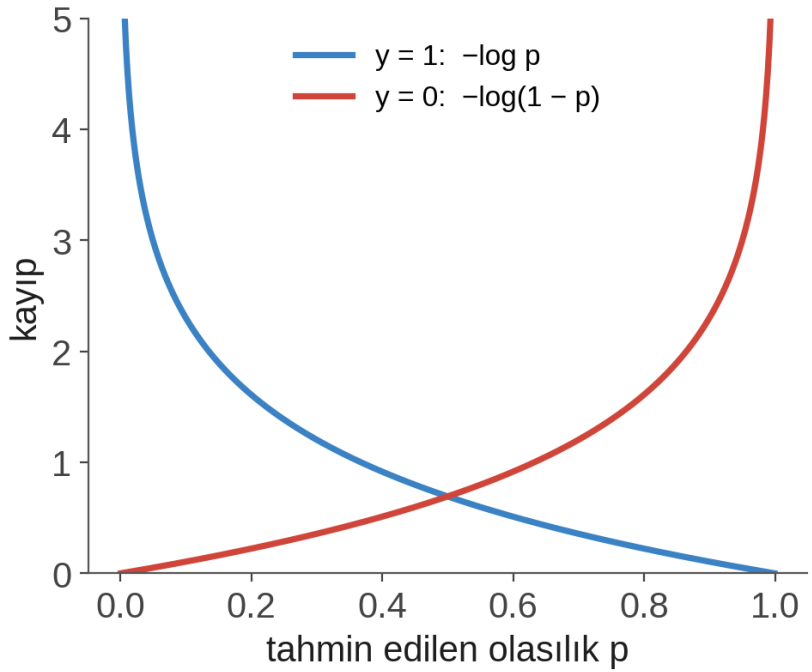


Sigmoid ve gradyan kaybı

- Doğrusal olmama için aktivasyon katmanı
- Çok büyük ve küçük girdilerde eğim kaybolur
  - Gradyanın kaybolması (vanishing gradients)
  - Bilgi kaybı
- Maksimum türev 0,25
- Alternatifler
  - tanh, ReLU, Leaky ReLU
  - GELU, SiLU (Swish), SwiGLU

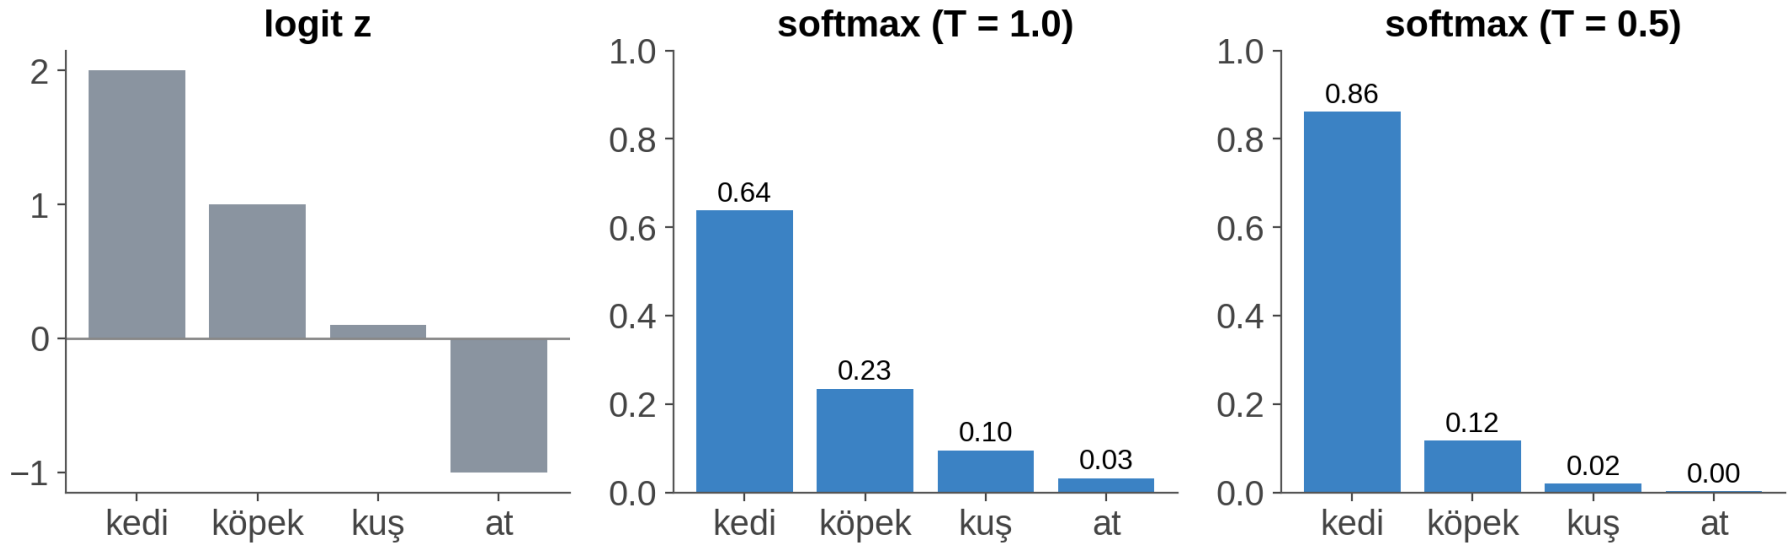
Öğrenme: kaybın hesaplanması

- Tahmin ile gerçek değer arasındaki fark
- Kayıp fonksiyonu
  - Regresyon: ortalama kare hata (MSE)
  - İkili sınıflandırma: ikili çapraz entropi
- $L = -[y \log p + (1 - y) \log(1 - p)]$

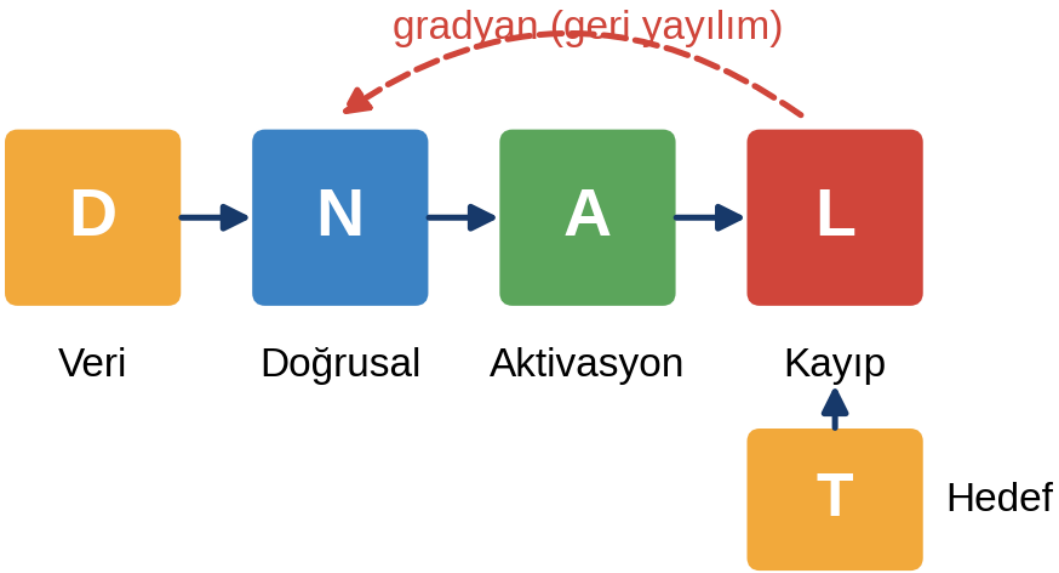


Çok sınıflı sınıflandırma

- Birden fazla sınıf için kayıp fonksiyonu
- Sigmoid yerine softmax
  - $p_i = \exp(z_i / T) / \Sigma_j \exp(z_j / T)$
- Kategorik çapraz entropi: L = –log p_doğru
- Sıcaklık T dağılımın keskinliğini ayarlar



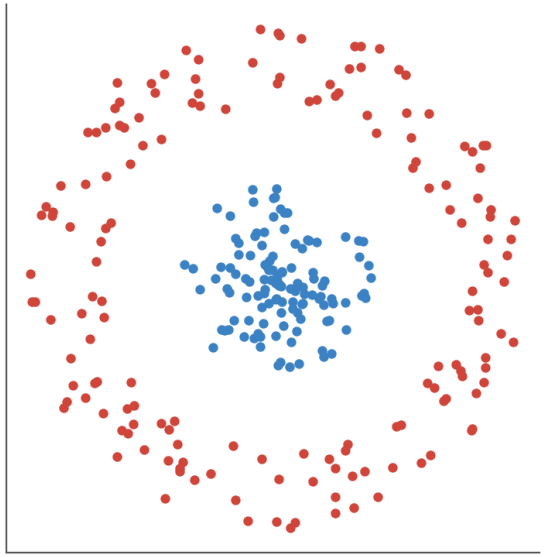
En temel yapay sinir ağı



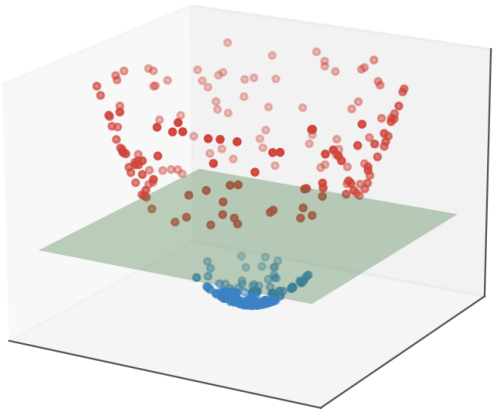
Boyut artırımı

- Doğrusal ayrılamayan sınıflar
- Veriyi daha yüksek boyutlu bir uzaya taşımak
- Yeni uzayda hiperdüzlem ile ayırma
- Gizli katmanlar bu dönüşümü veriden öğrenir

Girdi uzayı: doğrusal ayrılamaz

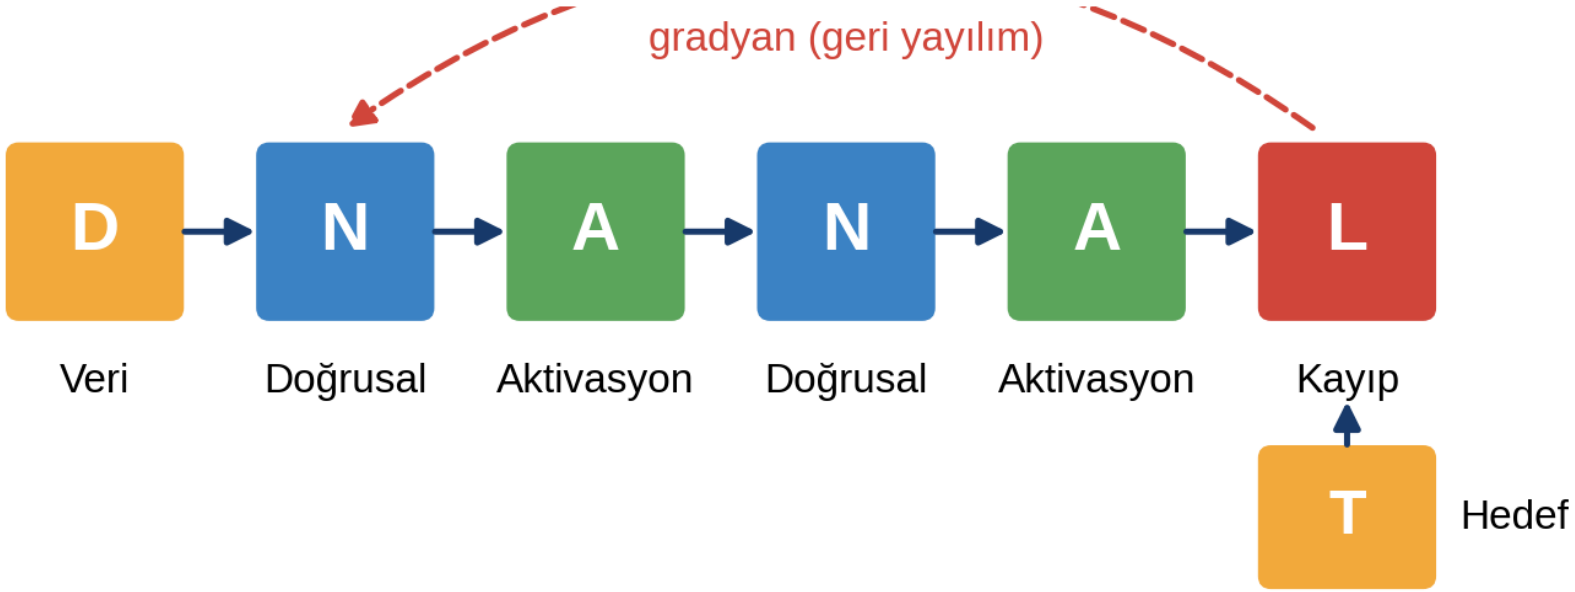


$z = x_1^2 + x_2^2$ eklenince: bir düzlem ayırır



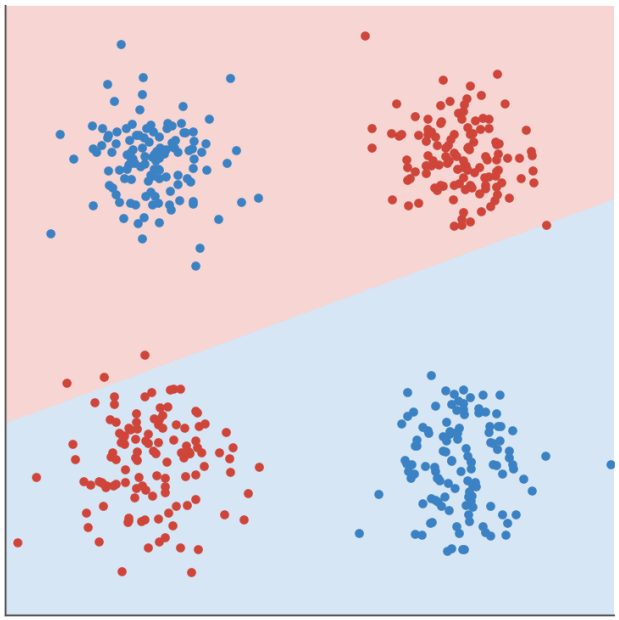
Daha derin sinir ağları

- Doğrusal katman + aktivasyon çiftleri art arda eklenir
- Her çift girdi uzayını yeniden büker
- Kayıp yalnız son katmanda hesaplanır, gradyan tüm katmanlara ulaşır

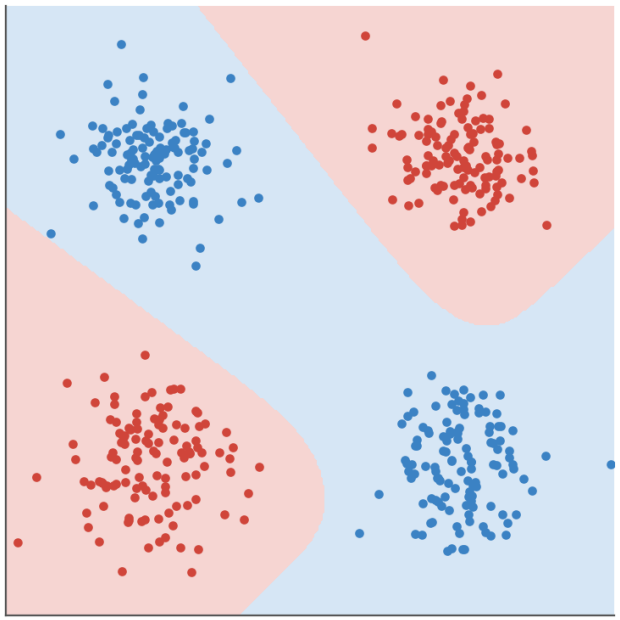


Derinliğin etkisi

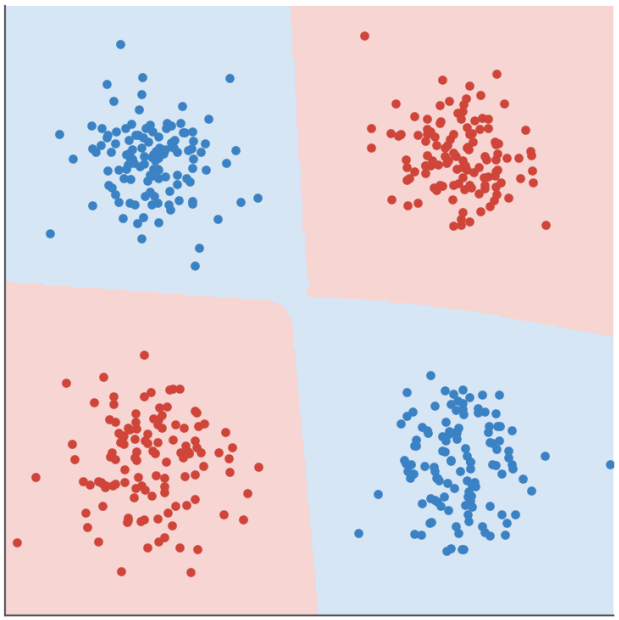
Gizli katman yok
doğruluk = 0.50



1 gizli katman (4 nöron)
doğruluk = 1.00

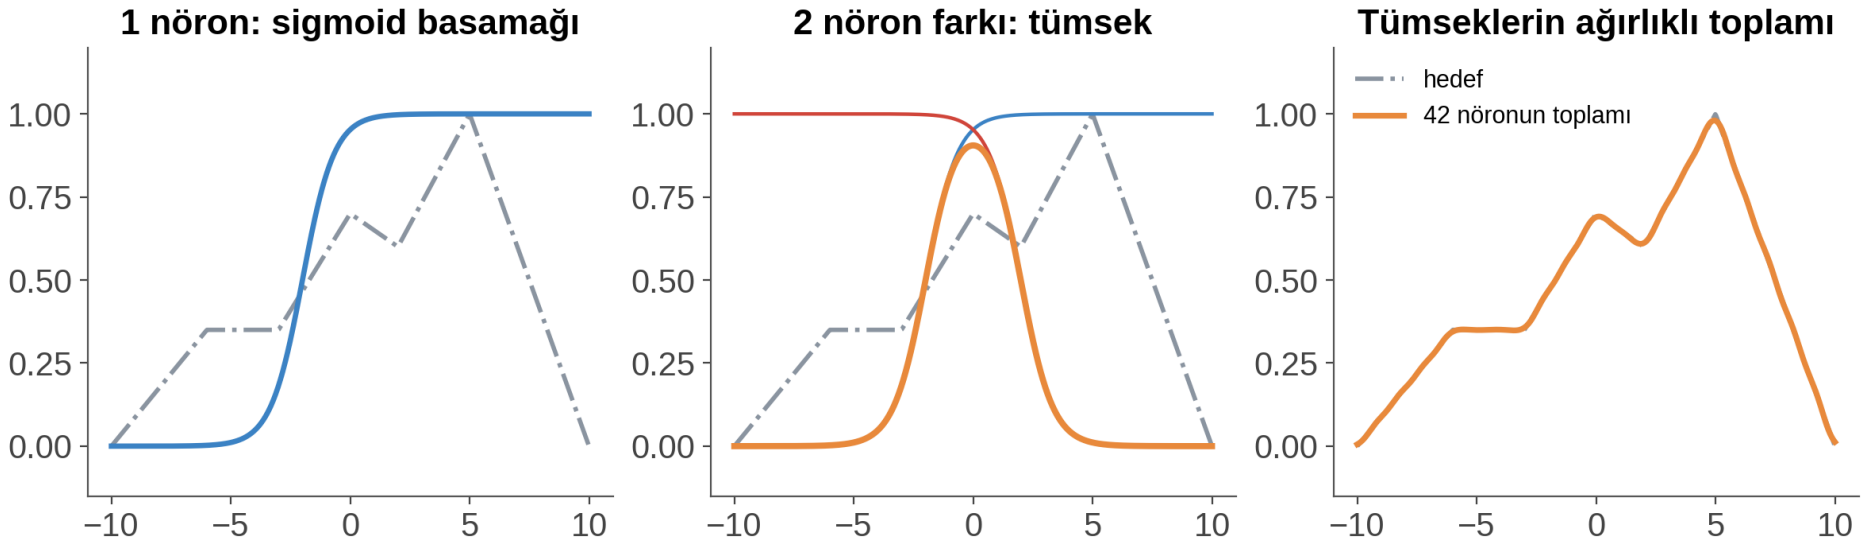


2 gizli katman (8, 8)
doğruluk = 1.00



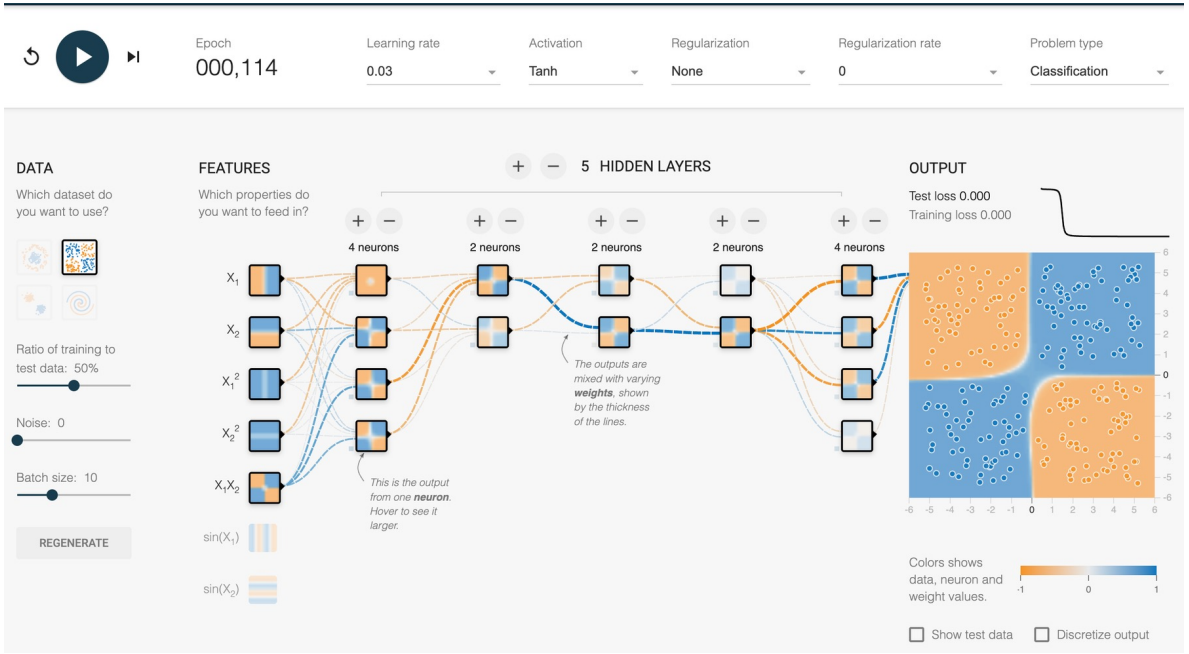
Evrensel yaklaşım

- Tek gizli katmanlı ağ yeterli sayıda nöronla
  - Sürekli fonksiyonlara istenen yakınlıkta yaklaşabilir
- İki sigmoid farkı → tümsek
- Tümseklerin ağırlıklı toplamı → fonksiyon
- Pratikte derinlik daha verimli



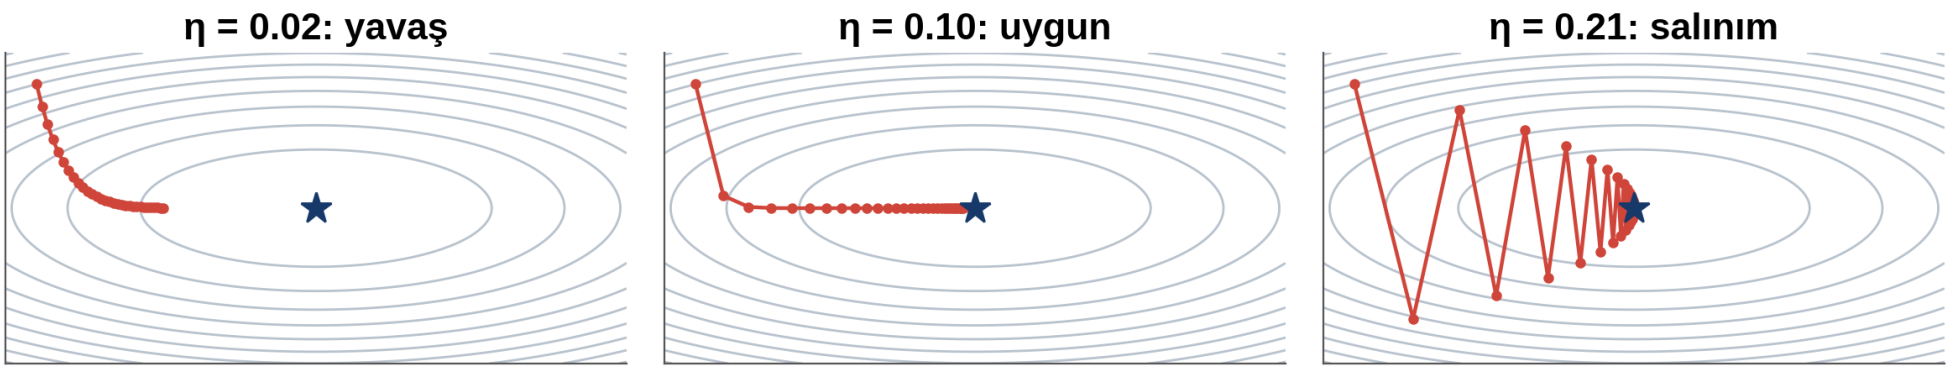
TensorFlow Playground

- playground.tensorflow.org
- Denenebilecekler
  - Katman ve nöron sayısı
  - Aktivasyon fonksiyonu
  - Öğrenme oranı ve düzenlileştirme
  - Girdi özellikleri



Gradyan inişi

- Amaç: kaybı en küçük yapan parametreler
- Gradyan: kaybın en hızlı arttığı yön
- Güncelleme: $\theta \leftarrow \theta - \eta \nabla L(\theta)$
- Öğrenme oranı η
  - Küçük: yavaş yakınsama
  - Büyük: salınım ya da ıraksama

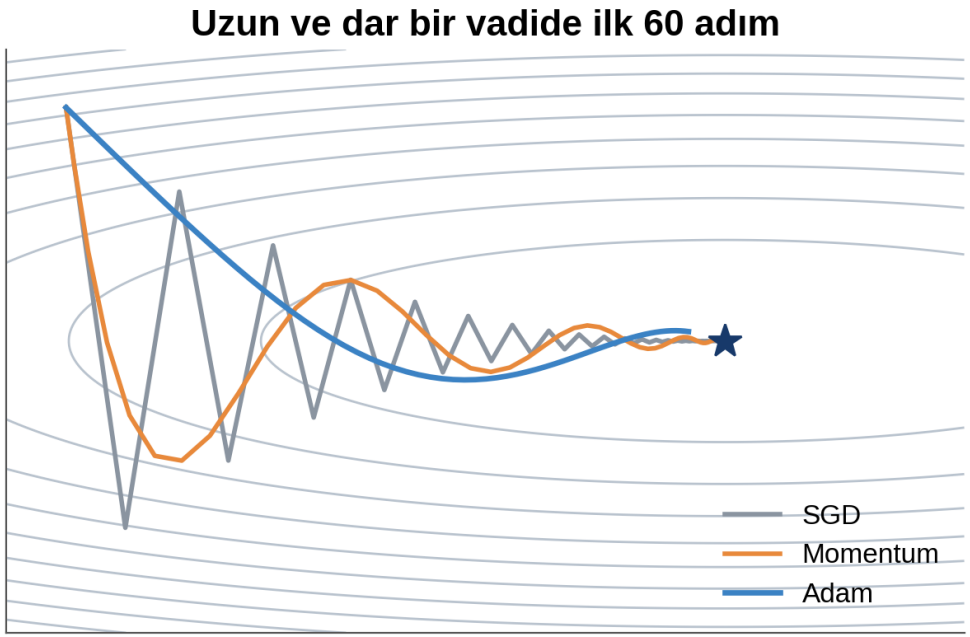


Stokastik ve mini-batch gradyan inişi

- Tüm veri üzerinden gradyan: pahalı
- Parçaların gradyanlarının ortalaması ≈ tüm gradyan
- Mini-batch: her adımda B örnek
- Tüm verinin belleğe sığması gerekmez
- Gürültülü gradyan düzenlileştirici etki yapar
- Epoch: verinin bir kez tamamen dolaşılması

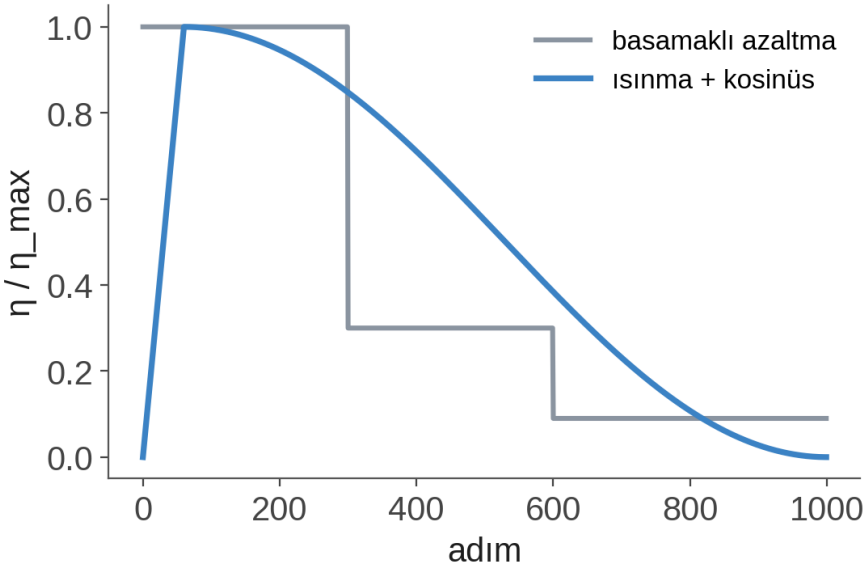
Optimizasyon algoritmaları

- SGD: yalnız güncel gradyan
- Momentum: geçmiş gradyanların hareketli ortalaması
- RMSProp: parametre başına ölçekleme
- Adam: momentum + ölçekleme
- AdamW: ağırlık azaltmayı ayrık uygular
- Başlangıç önerisi: AdamW



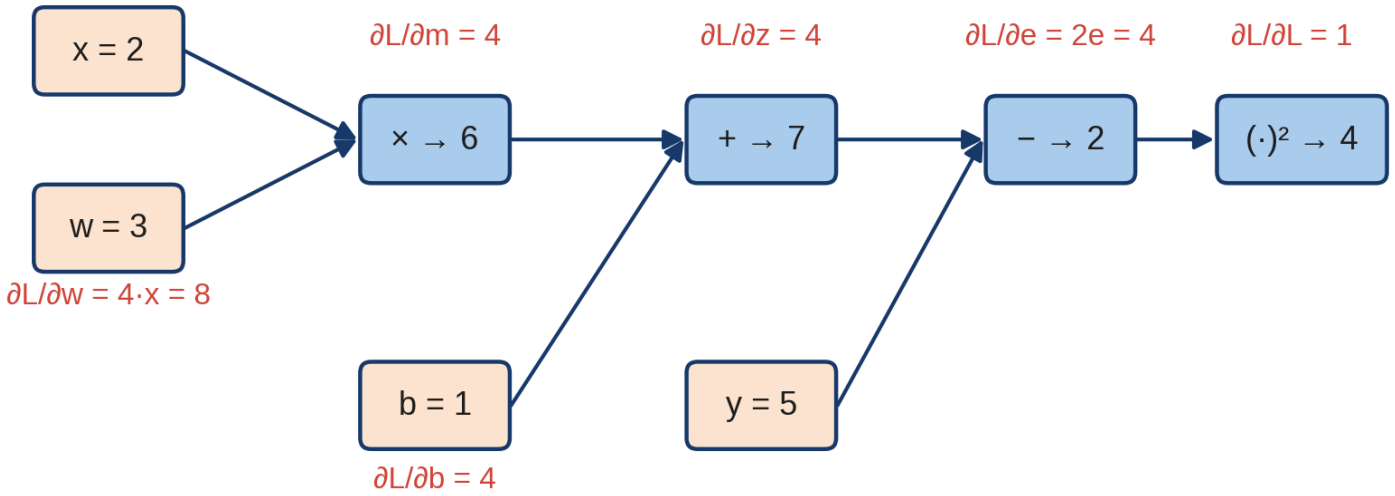
Öğrenme oranı zamanlaması

- Sabit öğrenme oranı çoğu zaman yetersiz
- Isınma (warmup): ilk adımlarda kademeli artış
- Azaltma
  - Basamaklı
  - Kosinüs
- Büyük modellerde ısınma + kosinüs yaygın



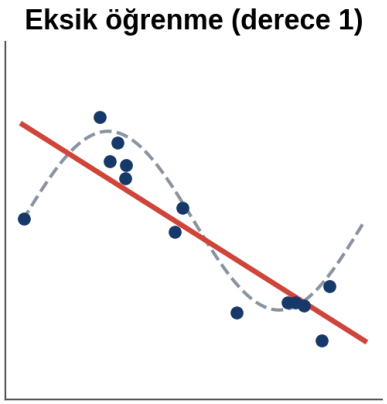
Geri yayılım: sayısal örnek

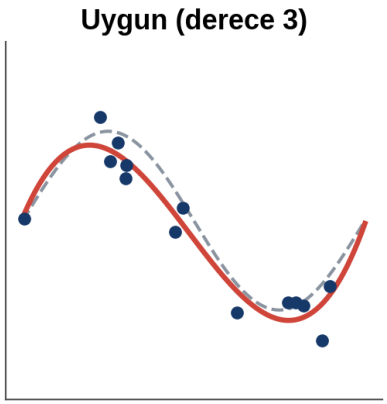
- $L = (w \cdot x + b - y)^2$
- $x = 2$, $w = 3$, $b = 1$, $y = 5$
- İleri geçiş: kayıp = 4
- Geri geçiş: zincir kuralı
  - $\partial L/\partial w = 8$, $\partial L/\partial b = 4$

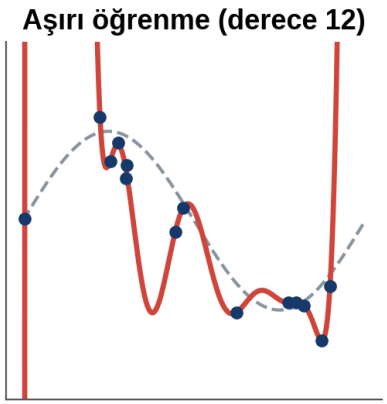


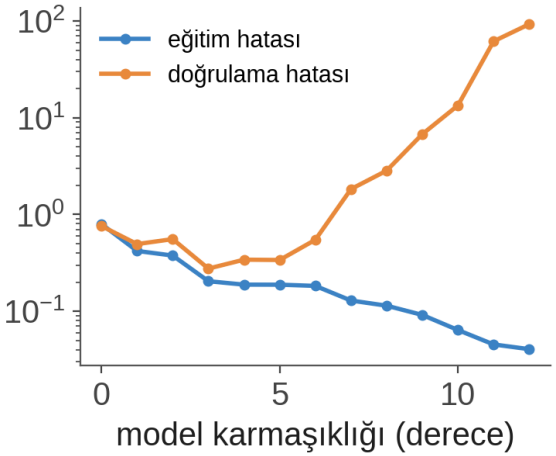
Aşırı öğrenme ve eksik öğrenme

- Eksik öğrenme: model çok basit
- Aşırı öğrenme: model eğitim verisini ezberler
- Eğitim hatası ↓, doğrulama hatası ↑
- Genelleme: görülmemiş veride başarı



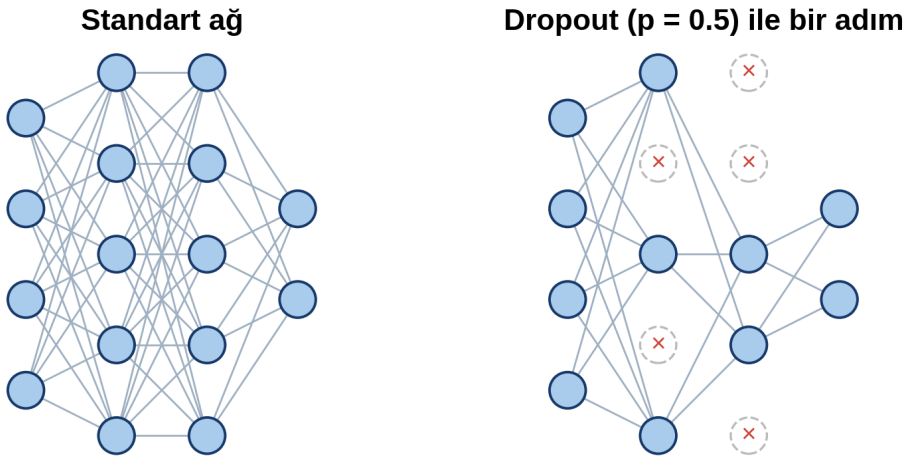






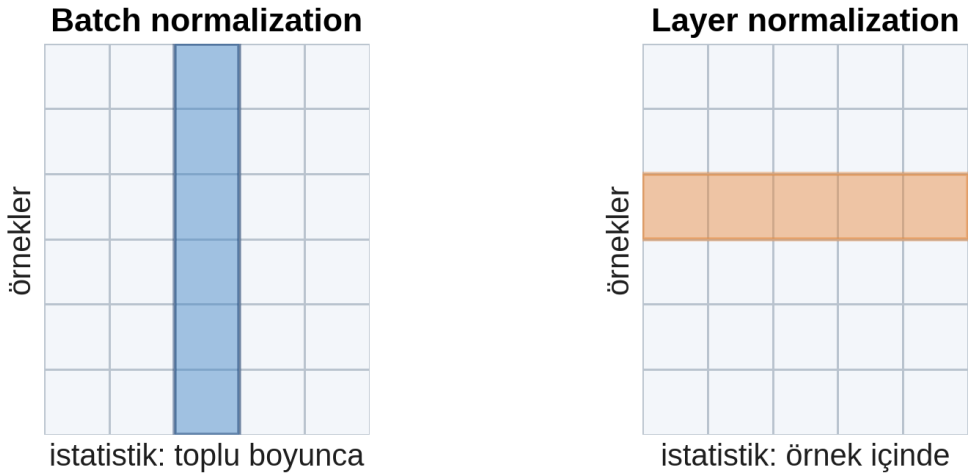
Düzenlileştirme

- Model karmaşıklığı aşırı öğrenmeye neden olabilir
- Karmaşıklığı sınırlamak
  - L2 (ağırlık azaltma), L1 (seyreklik)
  - Dropout
  - Erken durdurma
  - Veri artırma, girdiye gürültü



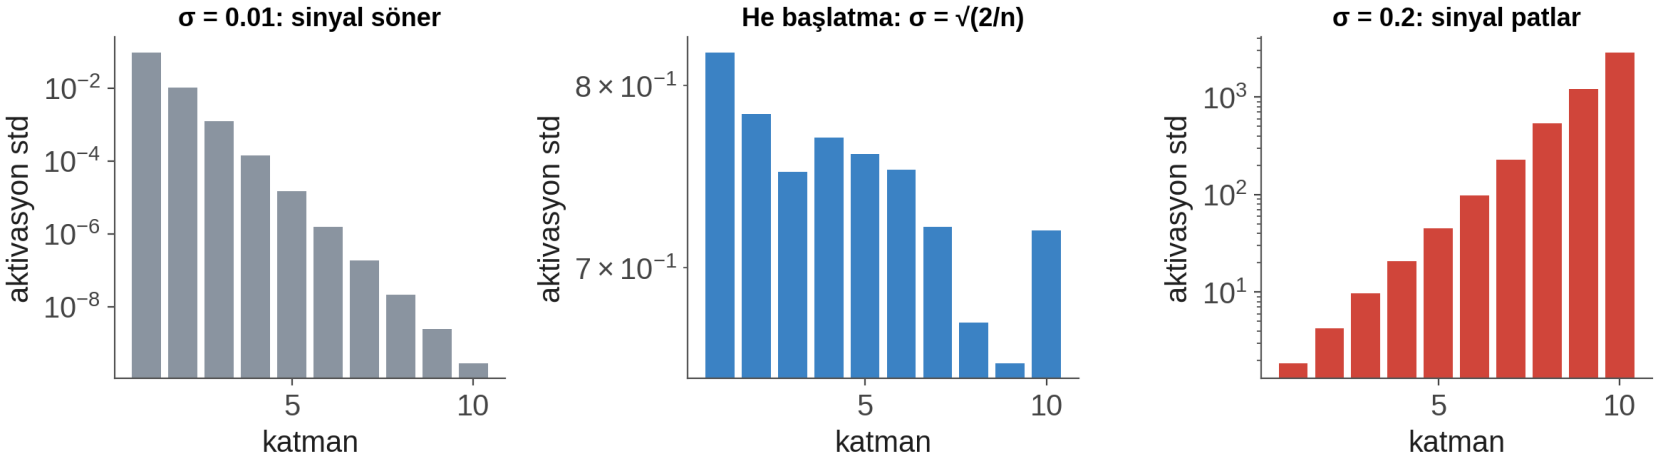
Normalizasyon

- Katman girdilerinin dağılımını sabitlemek
- Batch normalization
  - Toplu içindeki örnekler üzerinden
  - CNN'lerde yaygın
- Layer normalization
  - Tek örneğin özellikleri üzerinden
  - Transformer'larda standart
- RMSNorm: yalnız ölçekleme



Ağırlıkların başlatılması

- İlk ağırlık değerleri önemli
- Tümünün sıfır olması: simetri bozulmaz
- Çok küçük değerler: sinyal söner
- Çok büyük değerler: sinyal patlar
- Xavier (Glorot): tanh, sigmoid
- He (Kaiming): ReLU



Pratik öneriler – model ve kayıp

- Eğitim hatası sıfıra indirilebilir, genelleme hatası indirilemez
- Genişlik artışı: ifade gücünde polinom artış
- Derinlik artışı: ifade gücünde üstel artış
- Gizli katmanlarda sigmoid yerine ReLU
  - Negatifleri sıfırlar → ölü nöron riski
- Öğrenme = gradyan hesabı
  - Gradyanın büyüklüğü ağırlığın kayba etkisini gösterir

Pratik öneriler – eğitim süreci

- Optimizer olarak Adam / AdamW ile başlama
  - Nadir durumlarda değiştirmek gerekir
- Model önce küçük veride aşırı öğrenebilmeli
  - Öğrenemiyorsa: problem tanımı, veri ya da model hatalı
- Eğitim kaybı ve doğrulama kaybı birlikte izlenmeli
- Doğruluk her zaman doğru ölçüt değildir

Pratik öneriler – hata ayıklama

- Ağırlık ve gradyan normları incelenmeli
  - Sonsuza gidiyorsa ilgili katmanda sorun var
  - NaN değerleri: öğrenme oranı, log(0), bölme
- Tensör boyutları kontrol edilmeli
  - Yayınlama (broadcasting) sessiz hata üretebilir
- Aynı anda yalnız bir parametre değiştirilmeli
- Deneyler kaydedilmeli (tohum, yapılandırma, sonuç)

Pratik öneriler – önceden eğitilmiş modeller

- Transfer öğrenme
- İnce ayar (fine-tuning)
- PEFT: parametre verimli ince ayar
- LoRA: düşük ranklı uyarlama
- QLoRA: 4 bit nicemlenmiş model üzerinde LoRA