Derin Öğrenme

Evrişimli Sinir Ağları (CNN)

Hafta 3

Doç. Dr. Emir Öztürk
Trakya Üniversitesi · Bilgisayar Mühendisliği

Görüntü tanıma ve işleme

- Farklı uygulama alanları
  - Sağlık
  - Otonom sistemler
  - Güvenlik
- Yalnız nesnenin ne olduğu değil
  - Konumu
  - Hareketi
  - Sınırları

Uygulama örnekleri

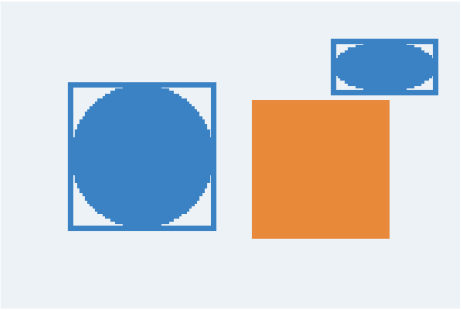
- Doküman okuma
  - Optik karakter tanıma (OCR)
  - El yazısı tanıma
- Tıp
  - Hastalık tespiti (radyoloji, patoloji, dermatoloji)
  - Otomatik raporlama desteği
- Otonom araçlar
- Endüstriyel kalite kontrol
- Uydu ve hava görüntüleri

Görsel görev türleri

Sınıflandırma



Nesne tespiti



Anlamsal bölütleme



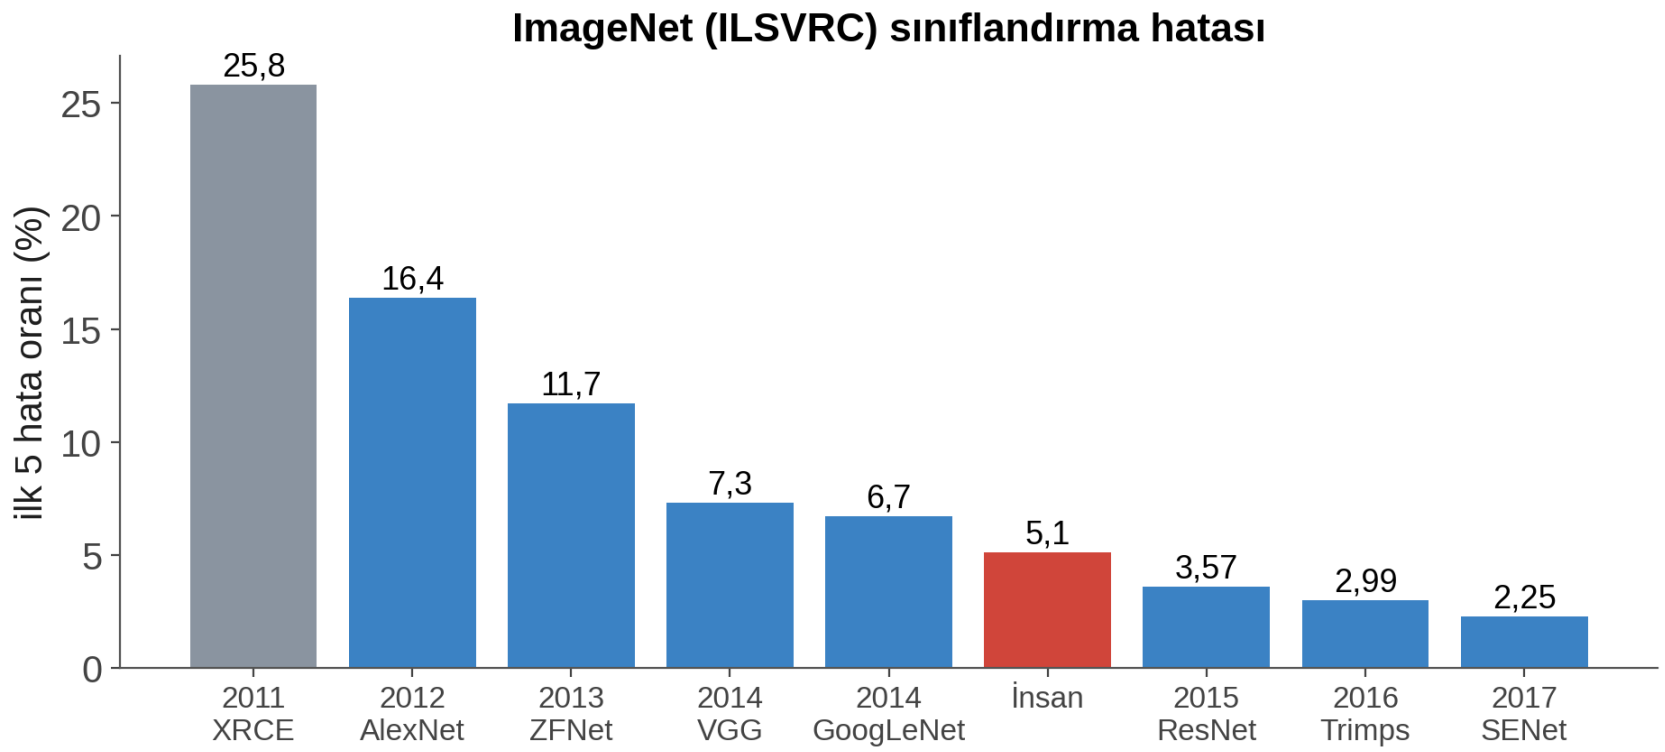
Örnek bölütleme



Görüntü sınıflandırma

- ImageNet yarışması (ILSVRC, 2010–2017)
  - 1,2 milyon eğitim görüntüsü, 1000 sınıf
- Erişilebilir ve etiketli büyük veri
- Klasik yöntemler
  - Elle tasarlanmış özellikler (SIFT, HOG)
  - Özellik + sınıflandırıcı (SVM)
  - Kural tabanlı ve öznel

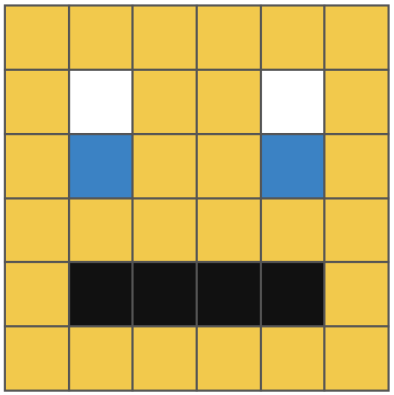
ImageNet sonuçları



Görüntülerin saklanması

- İki boyutlu piksel ızgarası
- Her renk için bir kanal (R, G, B)
- Saydamlık için ek kanal (alfa)
- Tensör boyutu: H × W × C
  - PyTorch: C × H × W

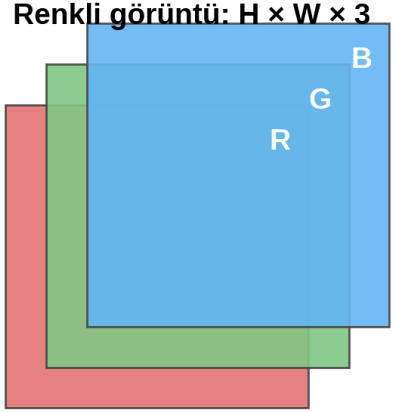
Görüntü (6 × 6)



Değer matrisi (renk indisi)

2	2	2	2	2	2
2	0	2	2	0	2
2	3	2	2	3	2
2	2	2	2	2	2
2	1	1	1	1	2
2	2	2	2	2	2

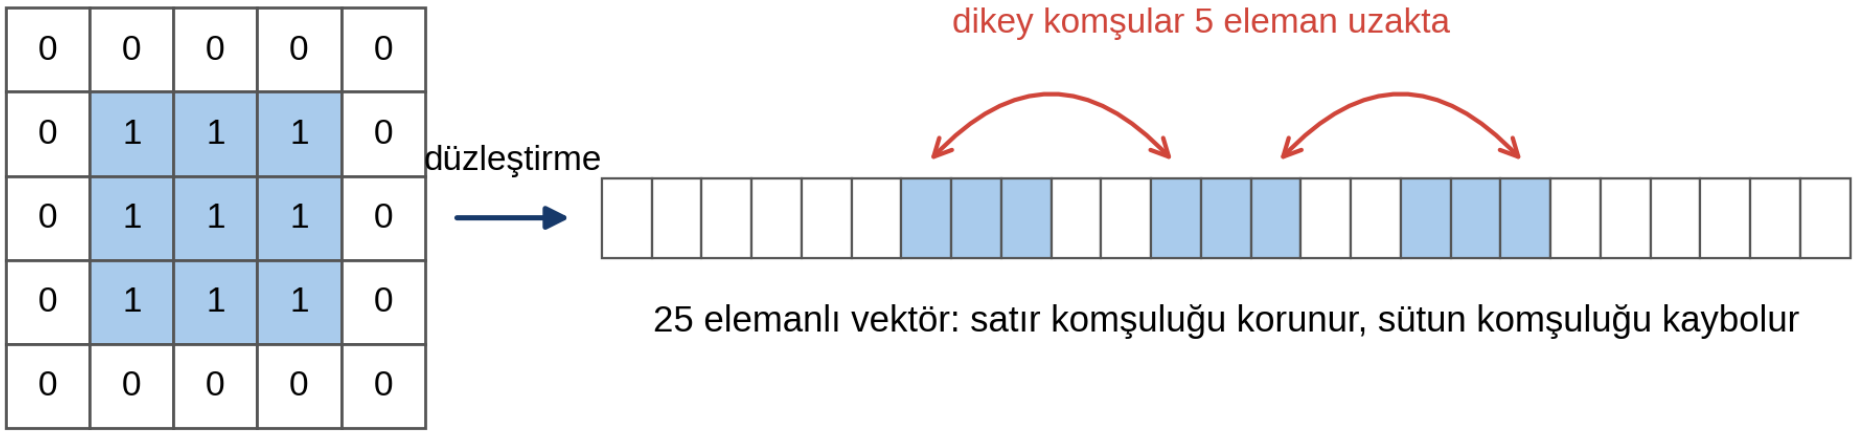
Renkli görüntü: H × W × 3



(+ saydamlık için 4. kanal)

Sinir ağına görüntünün verilmesi

- Tam bağlı katman vektör bekler
- Görüntü matris olarak saklanır
- Matristen vektöre dönüşüm: düzleştirme



Düzleştirmenin problemleri

- Yerellik kaybolur
- Öteleme: nesne kaydığında vektör tamamen değişir
- Farklı konumdaki aynı nesne için yeniden öğrenme

Nesne



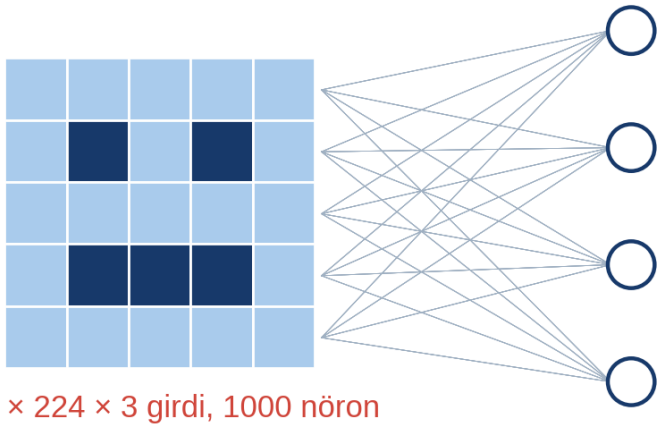
Aynı nesne, kaydırılmış



Düzleştirilmiş vektörlerde etkin elemanlar tamamen farklı indislerde

Tüm girdilerin tam bağlı kullanılması

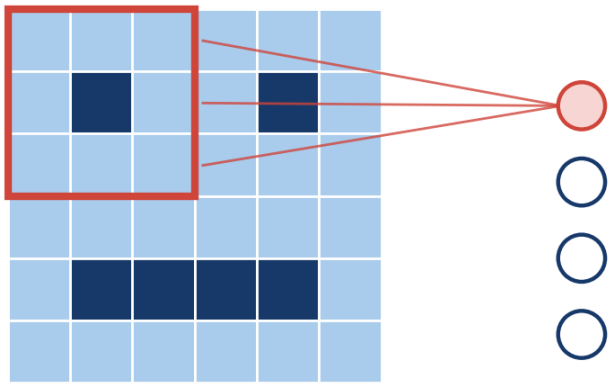
- İlişkisiz pikseller birbirine bağlanır
- Gereksiz karmaşıklık
- Parametre sayısı hızla büyür



224 × 224 × 3 girdi, 1000 nöron
≈ 150 milyon ağırlık

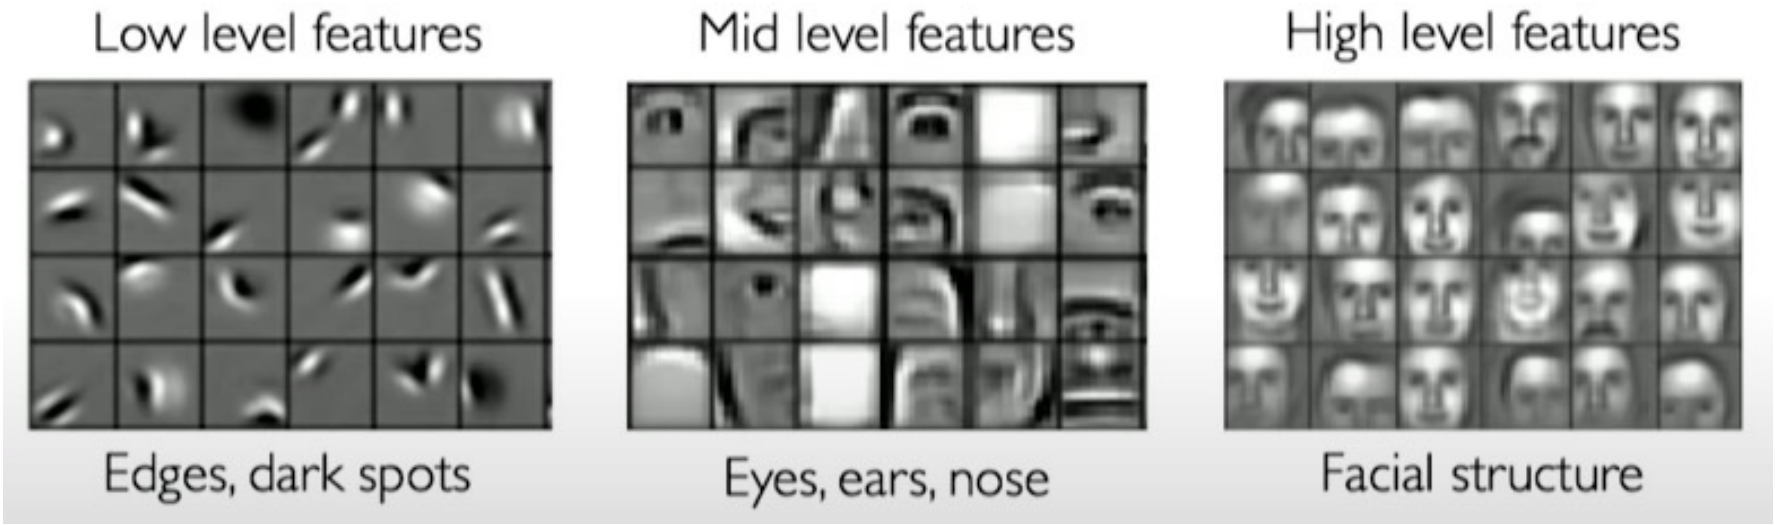
Yerelliğin sağlanması

- Tekrarlayan yerel örüntüleri tanımlamak
- Bu örüntüleri birleştirerek soyut özelliklere ulaşmak
- Özelliklerin elle çıkarılmasına alternatif
- Yerel bağlantı: her nöron küçük bir bölgeye bakar
- Ağırlık paylaşımı: aynı çekirdek her konumda



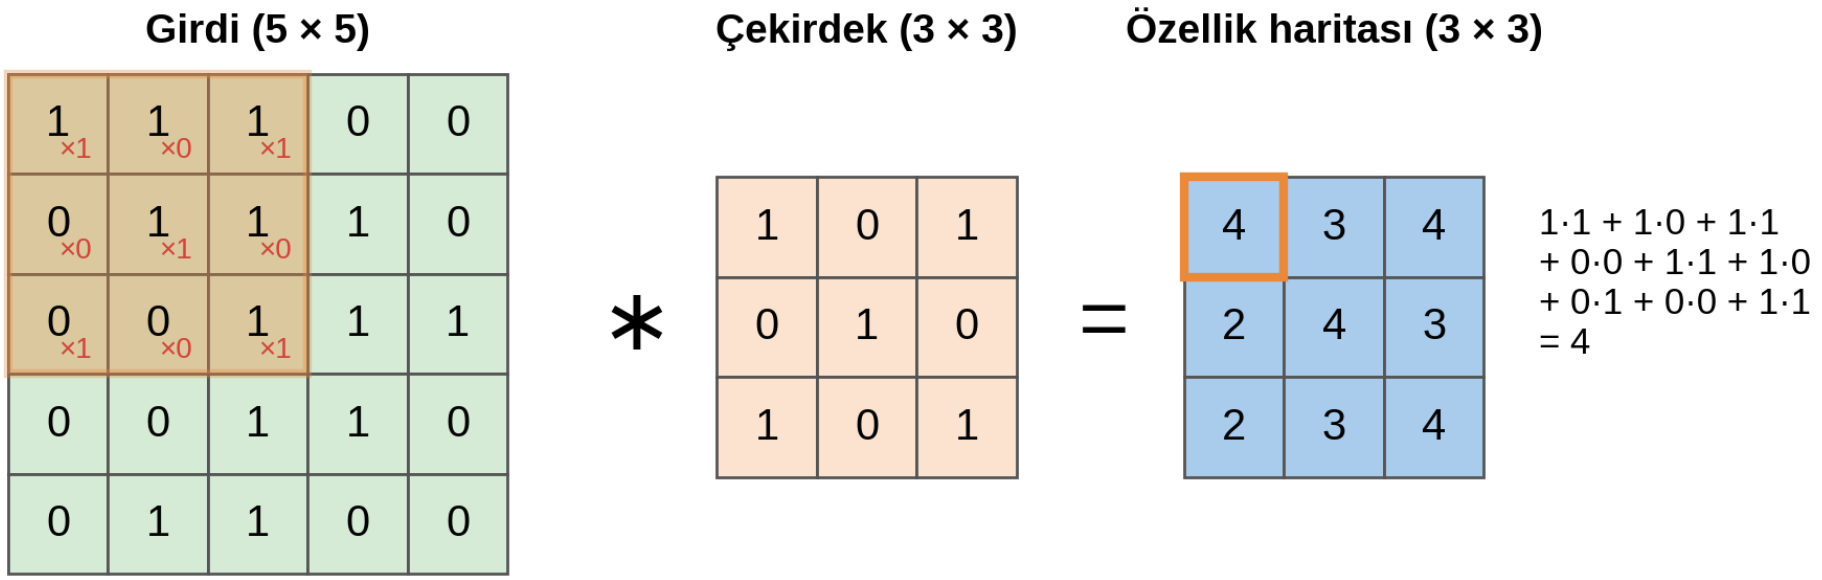
3 × 3 çekirdek: 9 ağırlık + 1 sapma
konumdan bağımsız, paylaşılır

Özellik hiyerarşisi



Lee, H. vd. (2009). Convolutional deep belief networks for scalable unsupervised learning of hierarchical representations. ICML.

Evrişim işlemi



Çekirdeğin etkisi

- Farklı çekirdekler farklı özellikler çıkarır
- Klasik görüntü işlemede çekirdekler elle tasarlanır
- CNN'de çekirdek değerleri öğrenilir

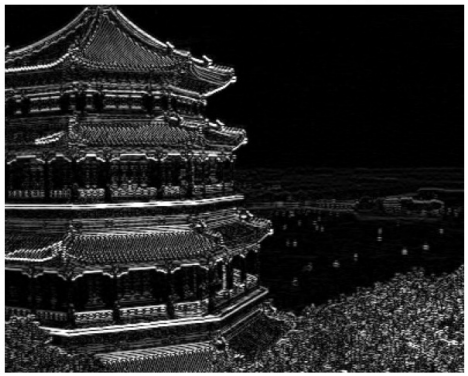
Girdi



Dikey kenar (Sobel x)



Yatay kenar (Sobel y)

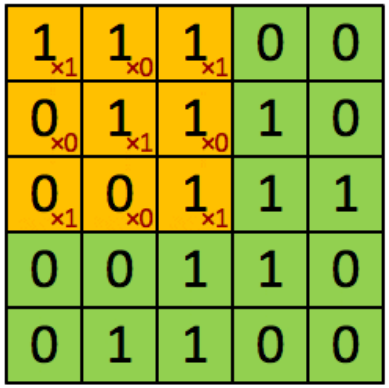


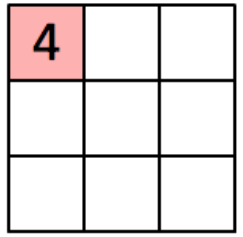
Bulanıklaştırma (5 × 5)



Çekirdek sayısı ve özellik haritaları

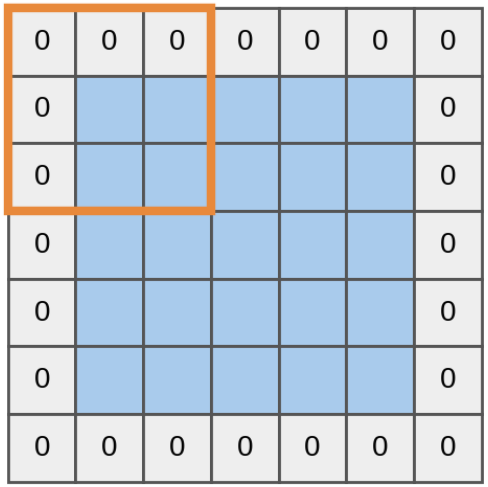
- Her çekirdek bir özellik haritası üretir
- Çıktı kanal sayısı = çekirdek sayısı
- Dolgusuz, adım 1 için çıktı boyutu
  - (W – K + 1) × (H – K + 1) × çekirdek sayısı



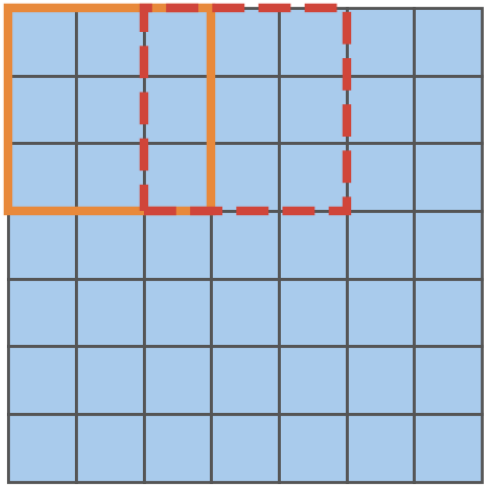


Dolgu ve adım

Dolgu (P = 1): 5 × 5 → 5 × 5



Adım (S = 2): 7 × 7 → 3 × 3



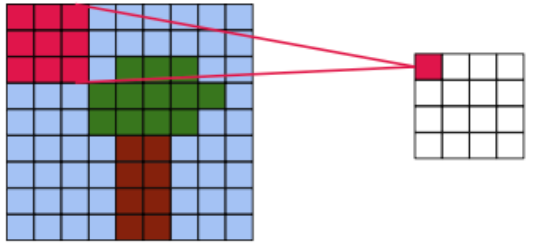
Çıktı boyutu

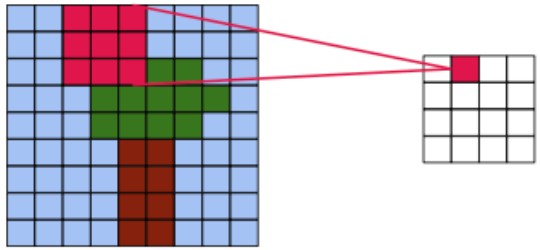
$$O = \left\lfloor \frac{W - K + 2P}{S} \right\rfloor + 1$$

W: girdi, K: çekirdek,
P: dolgu, S: adım

Özellik haritasını küçültme

- Kaynak kısıtı: haritalar büyük ve çok sayıda
- Yöntemler
  - Adımı artırmak
  - Havuzlama
  - Çekirdek boyutunu artırmak (dolgusuz)
  - Genişletilmiş evrişim
- Adım artınca bazı konumlar atlanır → bilgi kaybı

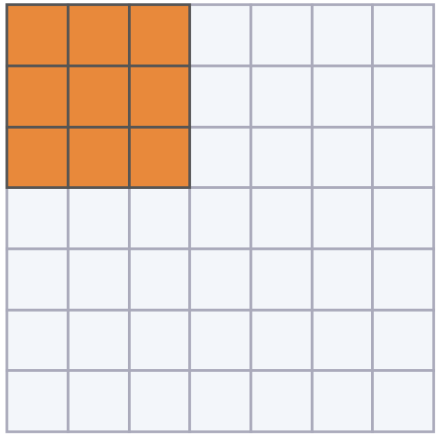




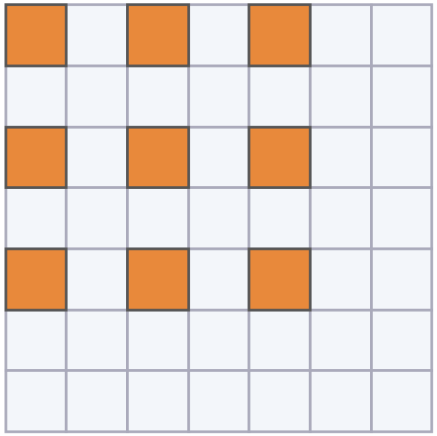
Genişletilmiş evrişim (dilated convolution)

- Çekirdek içinden yalnız belirli noktaları almak
- Parametre sayısı aynı, alıcı alan geniş
- Pencere kaydırmadaki kaybı azaltır
- Bölütleme ve ses modellerinde yaygın

d = 1: alıcı alan 3 × 3, 9 ağırlık

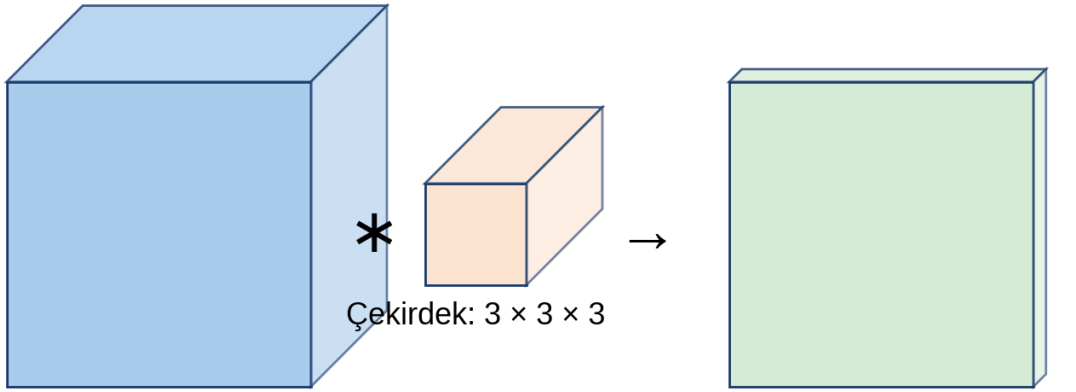


d = 2: alıcı alan 5 × 5, 9 ağırlık



Çok kanallı evrişim

- Önceki örnekler tek kanallı görüntüler
- Renkli görüntüde her kanal ayrı bir matris
- Çekirdek derinliği = girdi kanal sayısı
  - K × K × C_in
- Her çekirdek tek bir harita üretir



C_out çekirdek → C_out harita

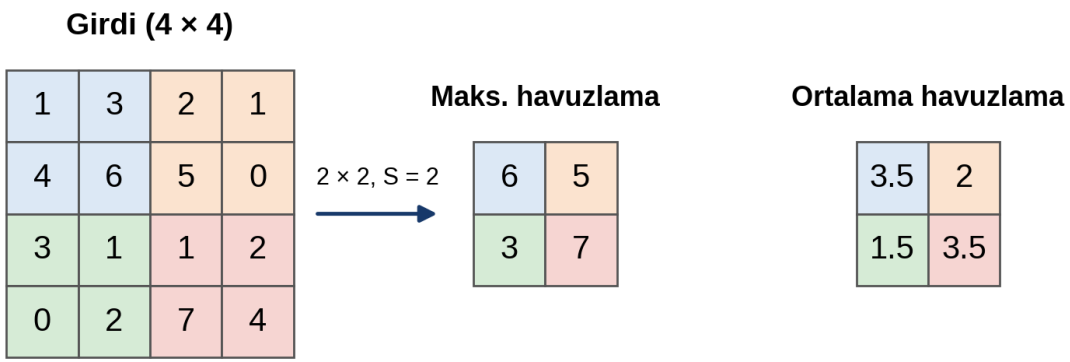
parametre sayısı:

K × K × C_in × C_out + C_out

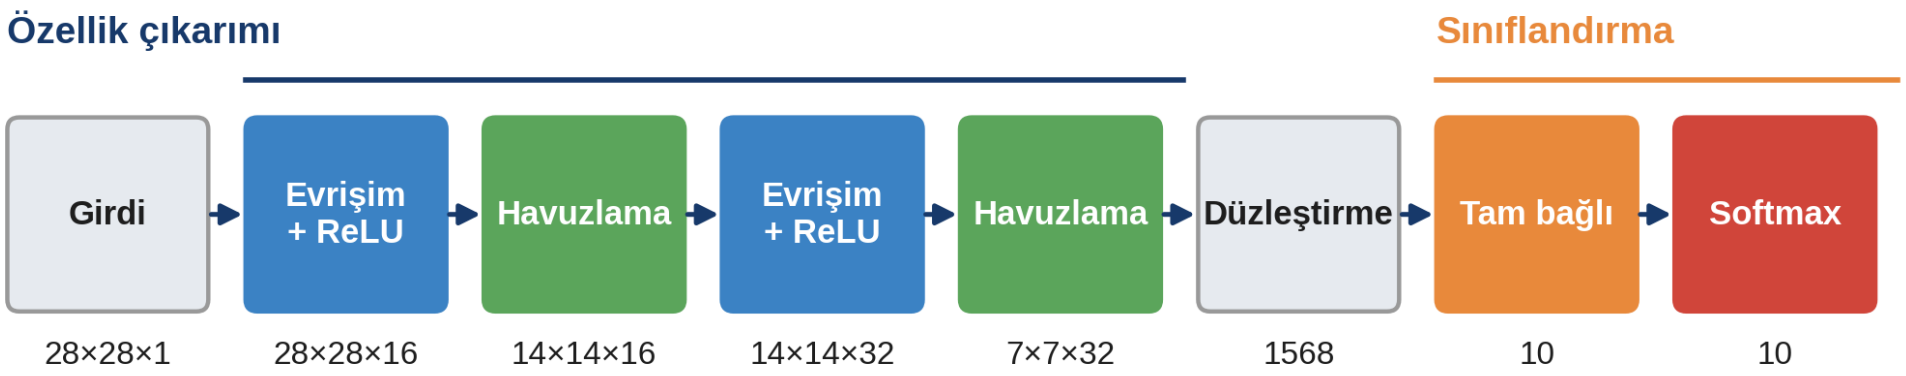
örn. 3×3×64×128 + 128 = 73 856

Havuzlama (pooling)

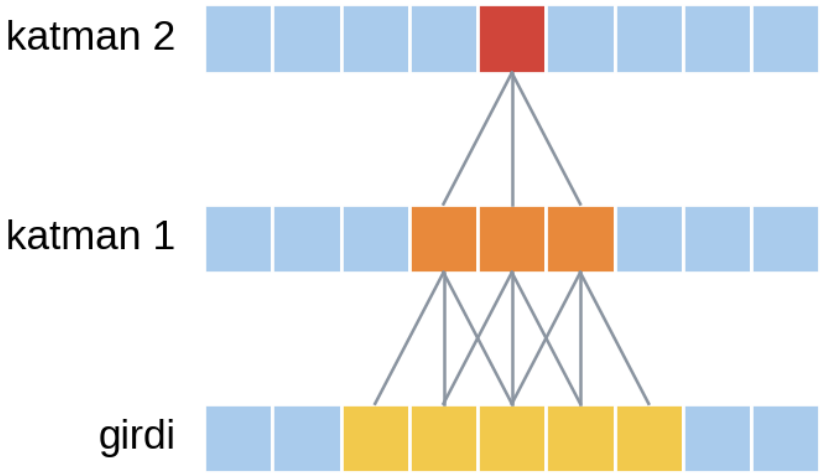
- Veri boyutunun küçültülmesi
- Bölge için bir temsilci seçilmesi
  - Maksimum
  - Ortalama
  - Minimum (nadiren)
- Öğrenilecek parametre yok
- Küçük kaymalara karşı dayanıklılık



En temel CNN


Özellik çıkarımı
Sınıflandırma
Girdi
Evrişim + ReLU
Havuzlama
Evrişim + ReLU
Havuzlama
Düzleştirme
Tam bağlı
Softmax
28×28×1
28×28×16
14×14×16
14×14×32
7×7×32
1568
10
10

Alıcı alan



İki 3×3 katman → 5×5 alıcı alan

Üç 3×3 katman → 7×7 alıcı alan

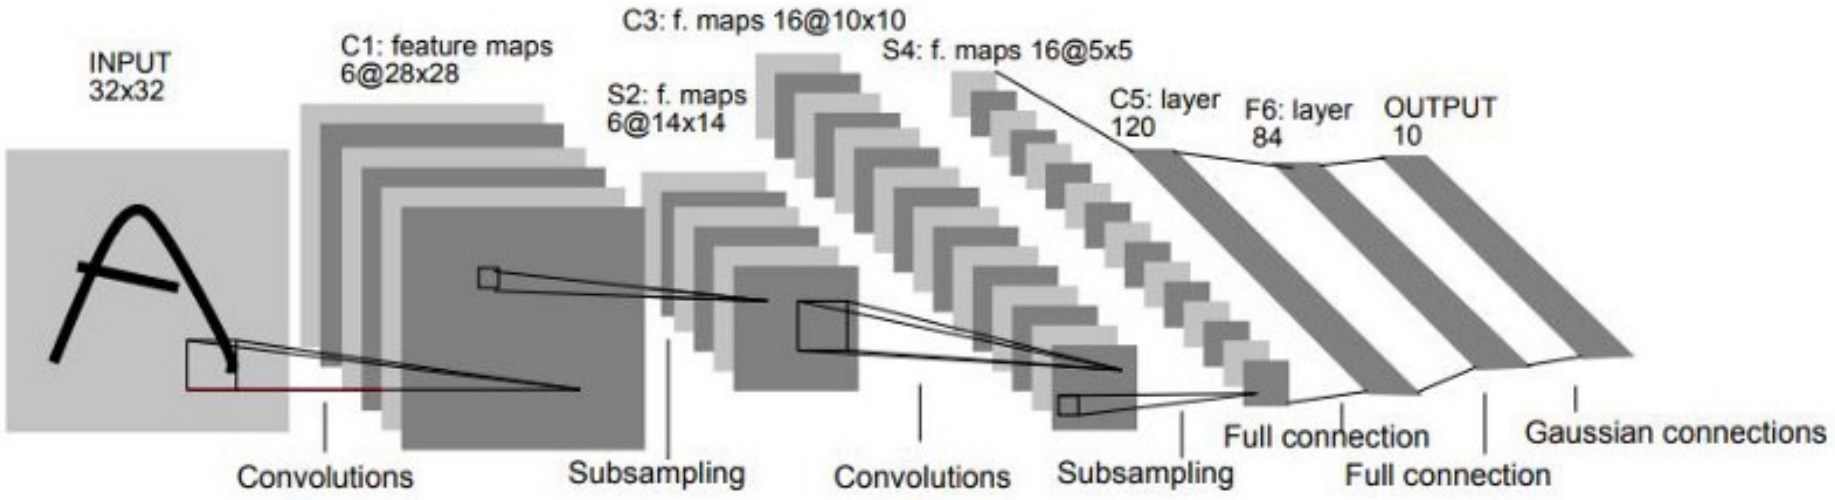
parametre: $3 \cdot (9C^2) = 27C^2$

tek 7×7 katman: $49C^2$

CNN mimarileri

LeNet-5

- LeCun vd. (1998)
  - İlk LeNet sürümü: 1989
- El yazısı rakam tanıma (çek okuma)
- Evrişim → alt örnekleme → evrişim → alt örnekleme → tam bağlı
- ~60 bin parametre



AlexNet

- Krizhevsky, Sutskever, Hinton (2012)
- CNN'i yaygınlaştıran mimari
- ReLU, dropout, veri artırma
- İki GPU üzerinde eğitim
- ~60 milyon parametre

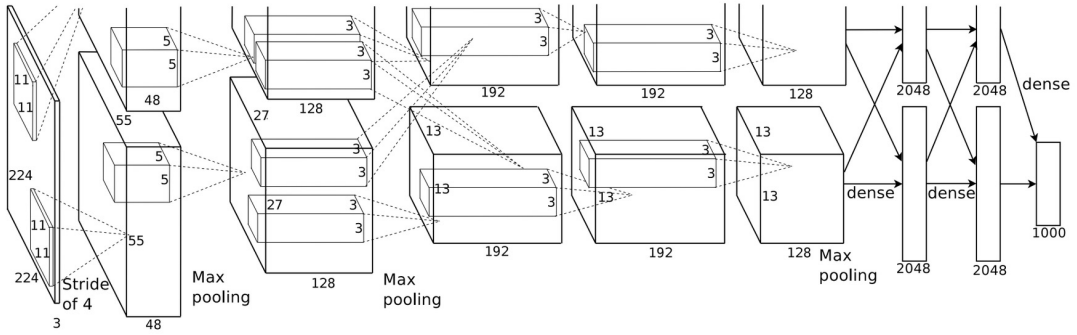
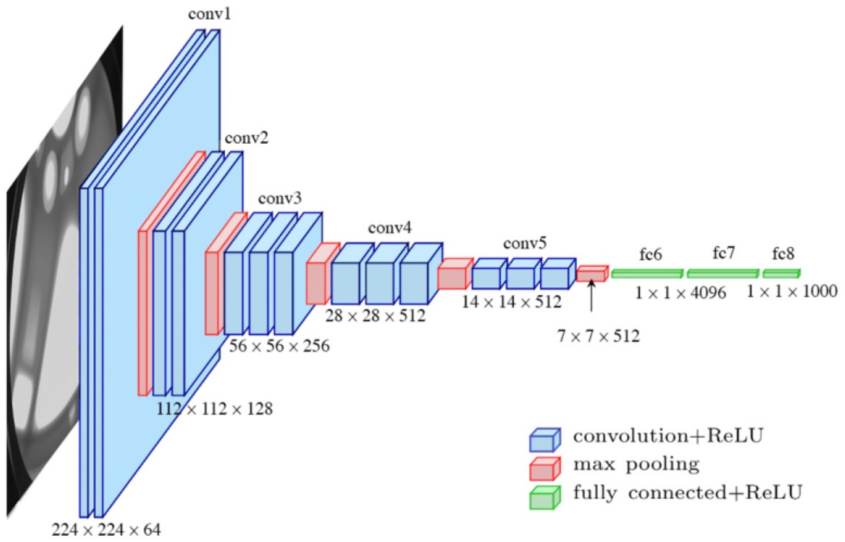


Figure 2: An illustration of the architecture of our CNN, explicitly showing the delineation of responsibilities between the two GPUs. One GPU runs the layer-parts at the top of the figure while the other runs the layer-parts at the bottom. The GPUs communicate only at certain layers. The network's input is 150,528-dimensional, and the number of neurons in the network's remaining layers is given by 253,440–186,624–64,896–64,896–43,264–4096–4096–1000.

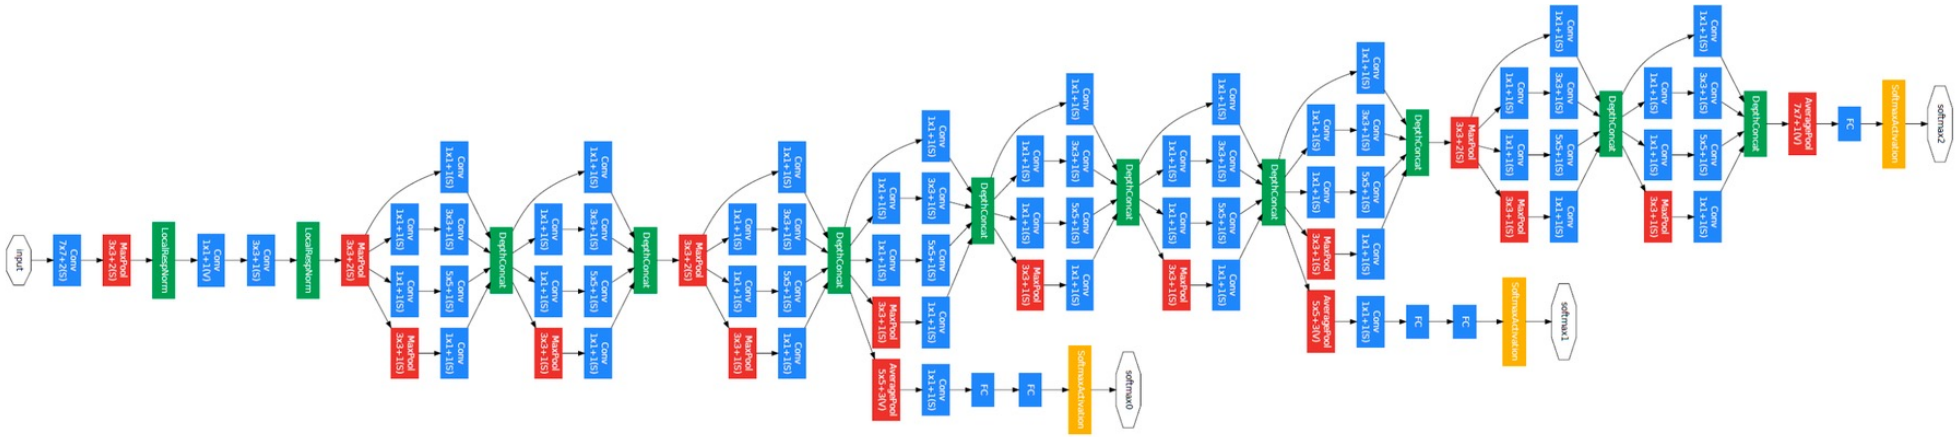
VGG

- Simonyan, Zisserman (2014)
- Yalnız 3 × 3 evrişim çekirdekleri
- Küçük çekirdeklerle derinlik: 16–19 katman
- Sade ve düzenli yapı
- ~138 milyon parametre



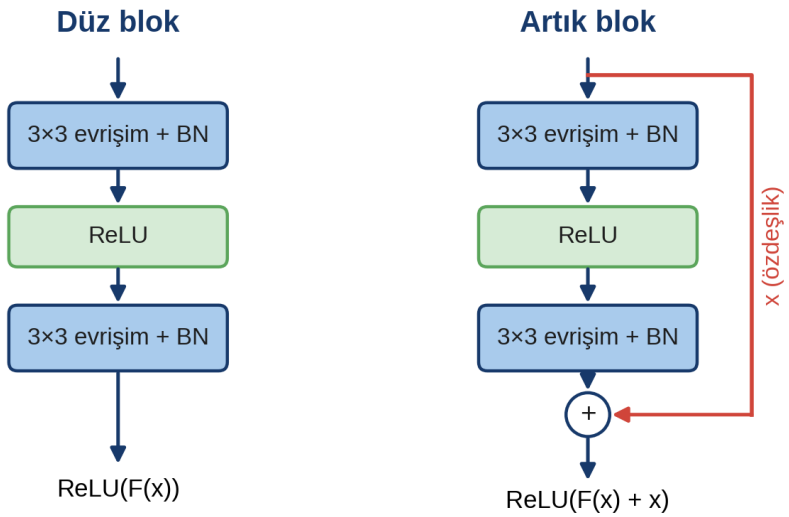
GoogLeNet (Inception)

- Szegedy vd. (2014)
- Inception modülü: paralel 1×1, 3×3, 5×5 evrişimler
- 1 × 1 evrişim ile kanal azaltma
- Global ortalama havuzlama
- AlexNet'ten ~12 kat az parametre (~7 milyon)



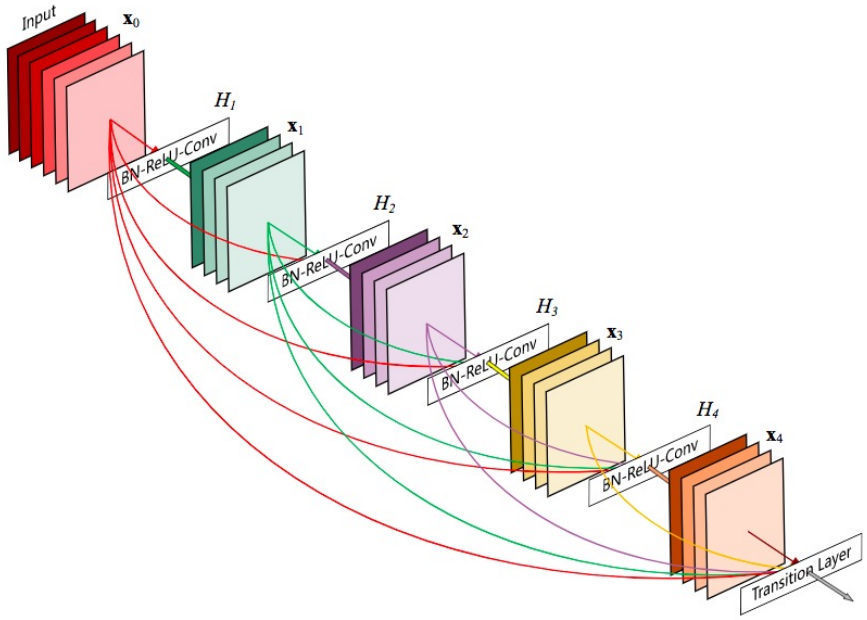
ResNet

- He vd. (2015)
- Derinlik artınca eğitim hatası da artıyordu
- Artık bağlantı: y = F(x) + x
- Gradyan kısayoldan doğrudan akar
- 152 katman, ILSVRC 2015 birincisi



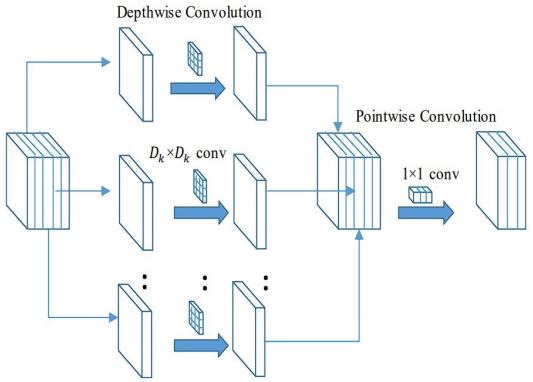
DenseNet

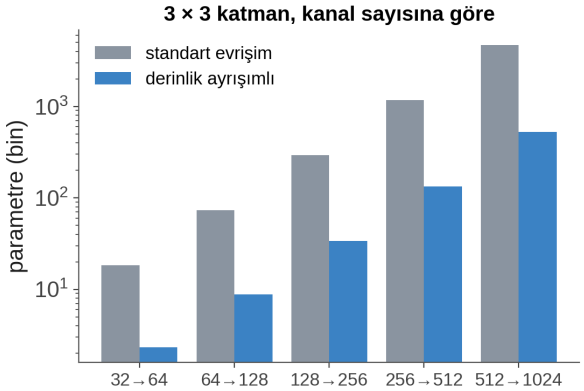
- Huang vd. (2017)
- Her katman önceki tüm katmanların çıktısını alır
- Toplama yerine kanal boyutunda birleştirme
- Özelliklerin yeniden kullanımı
- Daha az parametre ile benzer başarı



MobileNet ve derinlik ayrışımlı evrişim

- Howard vd. (2017)
- Mobil ve gömülü cihazlar için hafif model
- Evrişimi ikiye ayırma
  - Derinlik yönlü: her kanala ayrı K × K
  - Nokta yönlü: 1 × 1 ile kanalları karıştırma

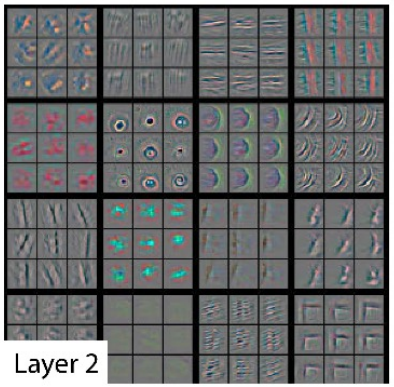


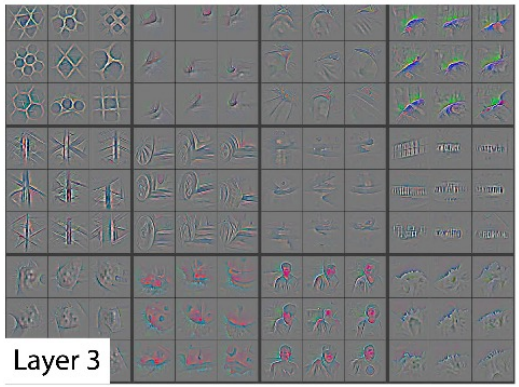


EfficientNet ve ConvNeXt

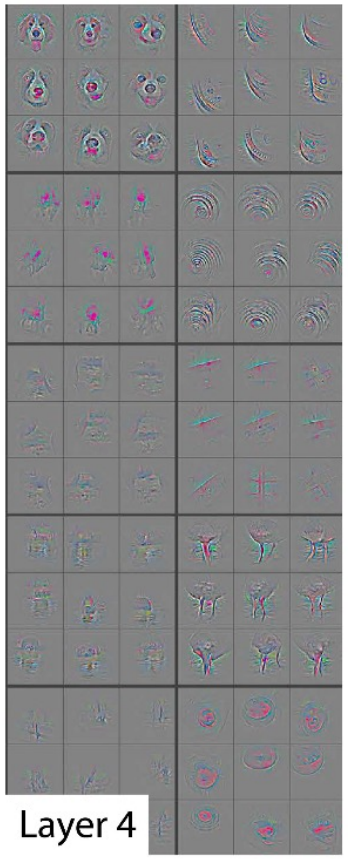
- EfficientNet (Tan, Le, 2019)
  - Derinlik, genişlik ve çözünürlüğü birlikte ölçekleme
  - Mimari arama ile bulunan temel ağ
- ConvNeXt (Liu vd., 2022)
  - ResNet'i Transformer tasarım kararlarıyla güncelleme
  - Büyük çekirdek, LayerNorm, GELU
  - ViT ile rekabetçi başarı

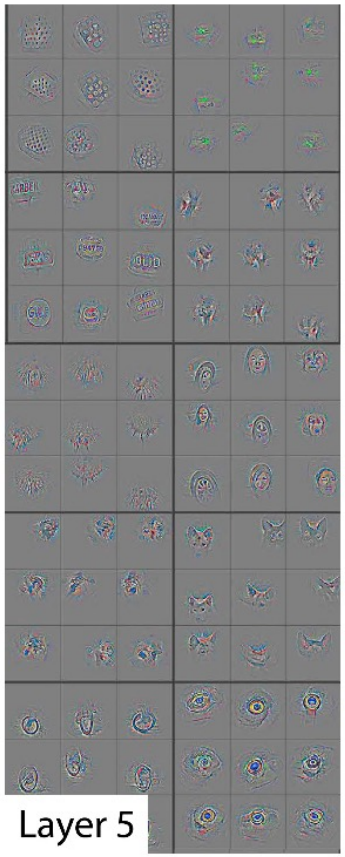
CNN'in öğrendikleri





Figures from Zeiler et al. (2014)



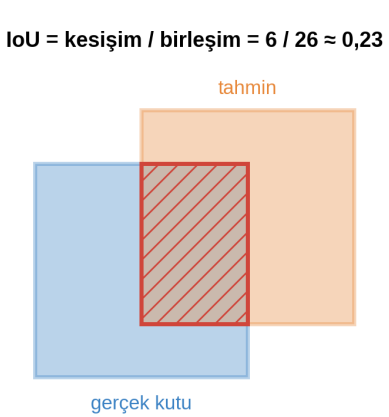


Zeiler, M. D., Fergus, R. (2014). Visualizing and understanding convolutional networks. ECCV. — distill.pub/2017/feature-visualization

Tespit ve bölütleme

Nesne tespiti: temel kavramlar

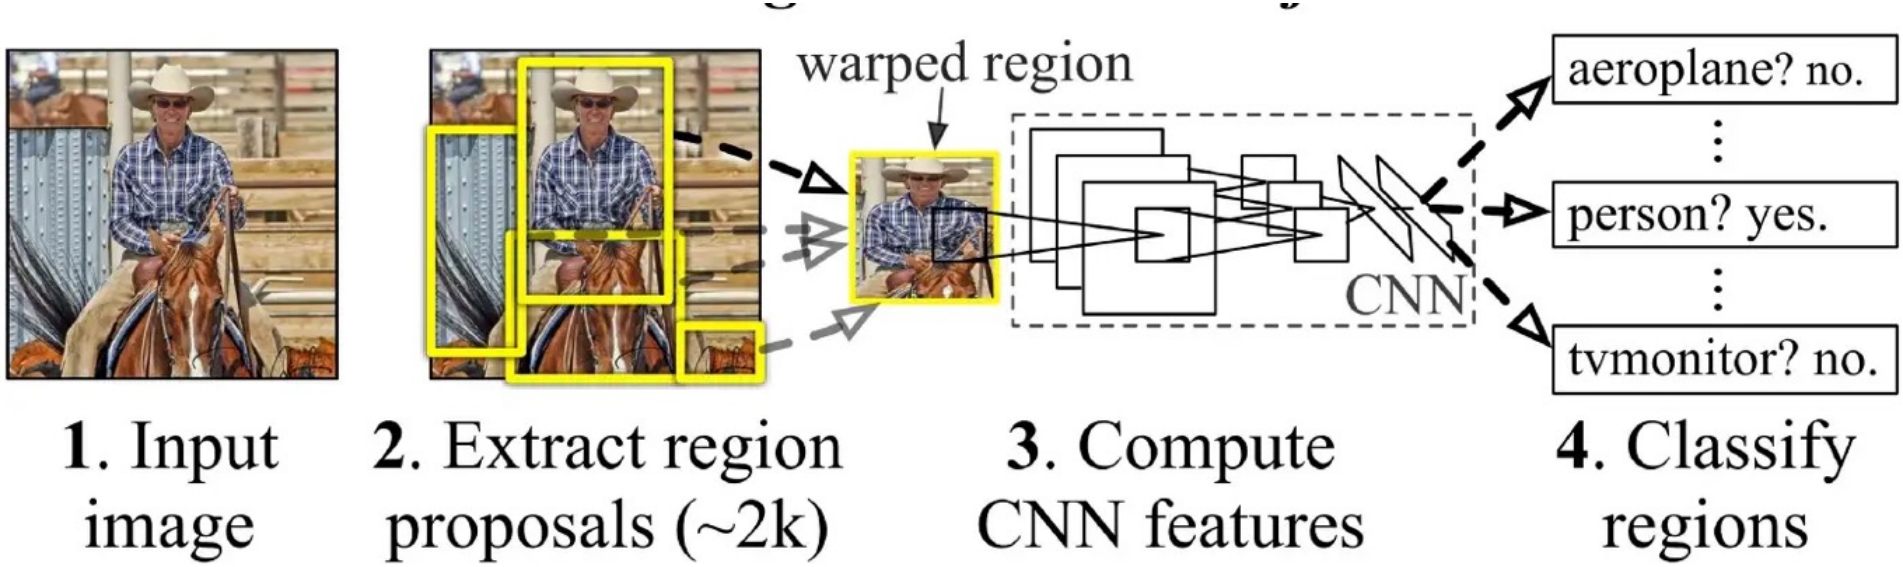
- Çıktı: sınırlayıcı kutu + sınıf + skor
- IoU: kesişim / birleşim
  - Tahminin doğru sayılması için eşik (ör. 0,5)
- NMS: aynı nesneye ait fazla kutuların elenmesi
- Başarı ölçütü: mAP





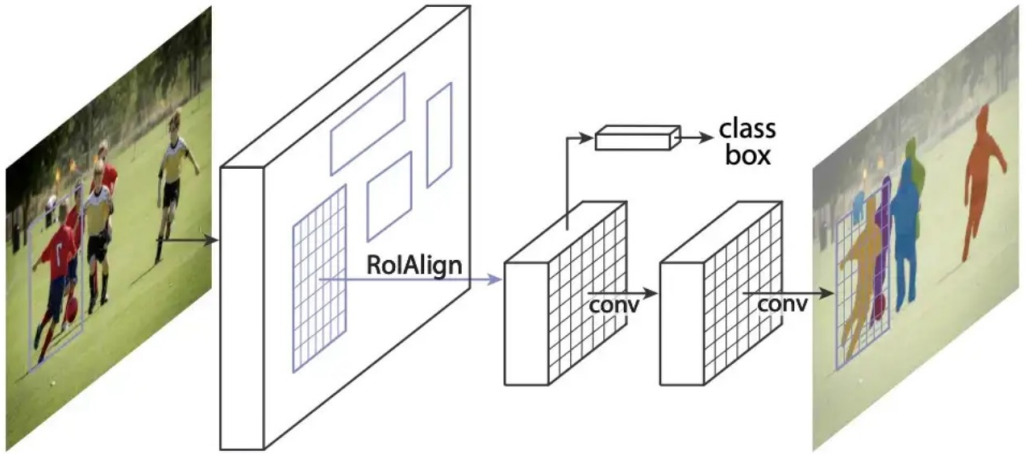
İki aşamalı tespit: R-CNN ailesi

- R-CNN (2014): aday bölge önerisi + CNN
- Fast R-CNN (2015): özellik haritası bir kez hesaplanır
- Faster R-CNN (2015): bölge öneri ağı (RPN)
- Yüksek doğruluk, daha yavaş çıkarım



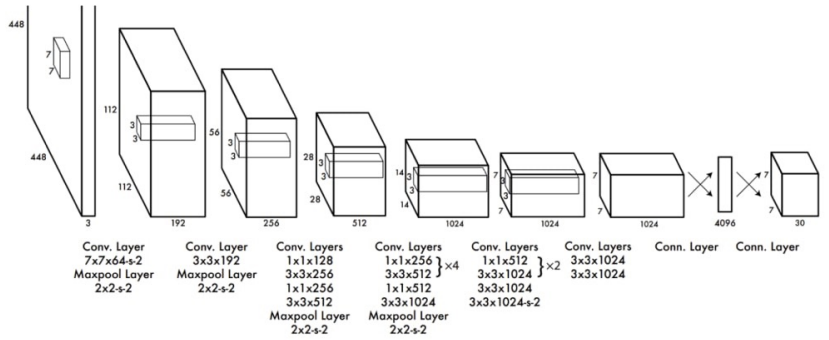
Mask R-CNN

- He vd. (2017)
- Faster R-CNN + maske dalı
- Örnek bölütleme
- RoIAlign: daha keskin konum
- Tespit ve maske için ayrı başlıklar



YOLO

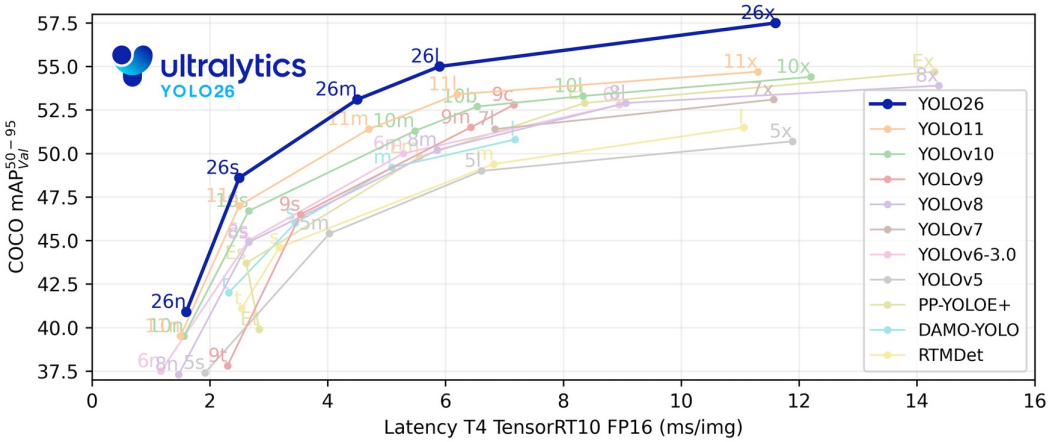
- Redmon vd. (2016): You Only Look Once
- Tek aşamalı tespit
  - Görüntü ızgaraya bölünür
  - Her hücre kutu ve sınıf tahmin eder
- Gerçek zamanlı çıkarım



The Architecture. Our detection network has 24 convolutional layers followed by 2 fully connected layers. Alternating 1×1 convolutional layers reduce the features space from preceding layers. We pretrain the convolutional layers on the ImageNet classification task at half the resolution (224×224 input image) and then double the resolution for detection.

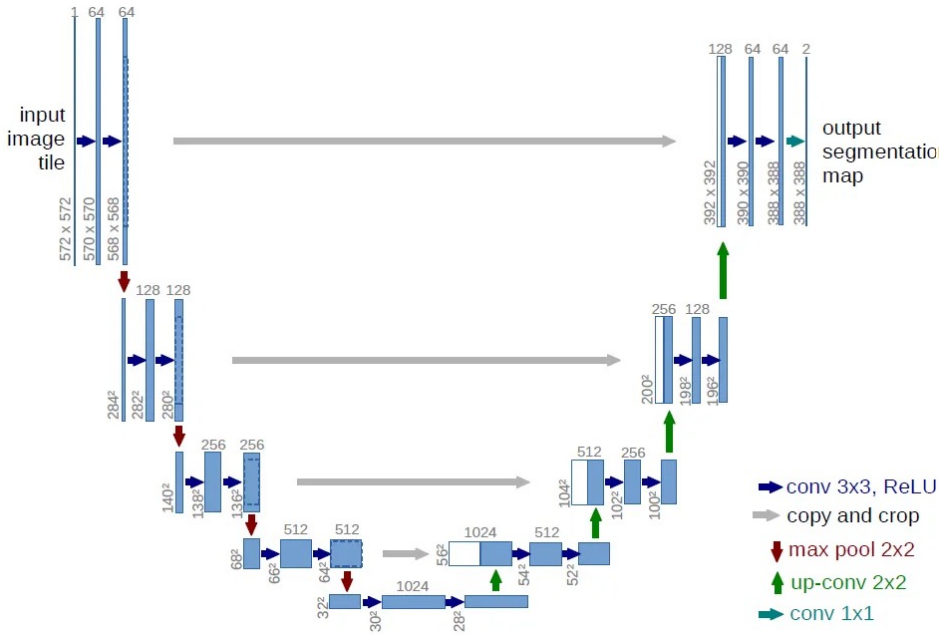
YOLO sürümleri

- v2–v3: çapa kutuları, çok ölçekli tahmin
- v4–v8: omurga ve eğitim iyileştirmeleri
- DETR (2020): Transformer ile tespit, NMS gerektirmez
- Güncel sürümler: NMS'siz uçtan uca tespit

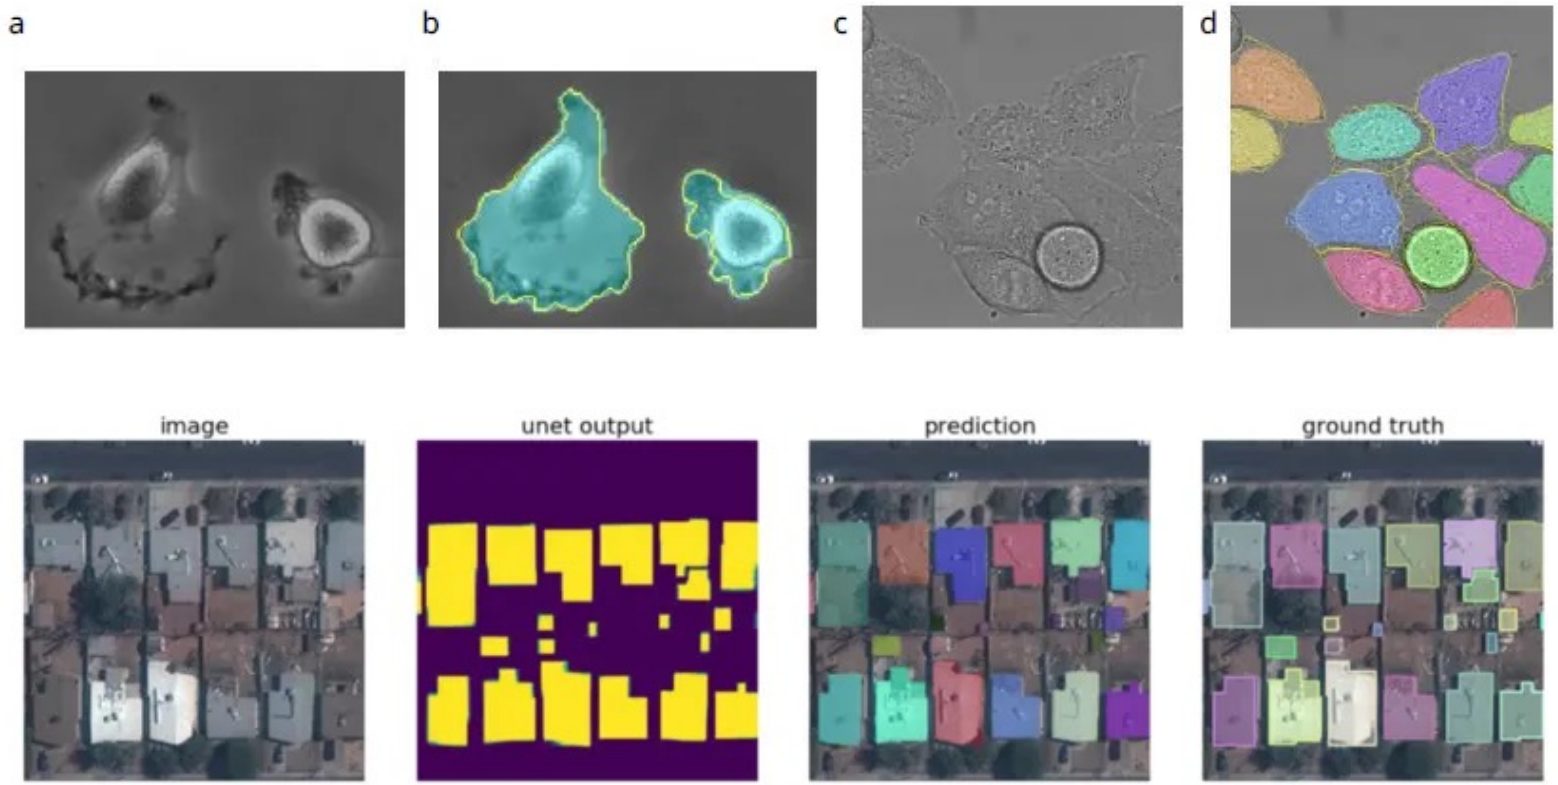


U-Net ve anlamsal bölütleme

- Ronneberger vd. (2015)
- Kodlayıcı: evrişim + havuzlama ile küçültme
- Kod çözücü: yukarı örnekleme ile büyütme
- Atlama bağlantıları: ayrıntılı konum bilgisi
- Az veri ile biyomedikal bölütleme



U-Net örnekleri



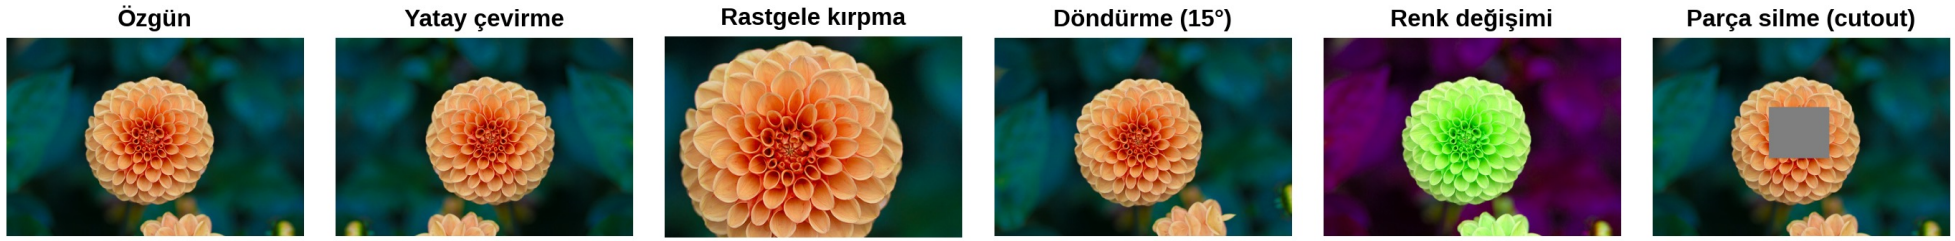
Temel bölütleme modelleri

- Segment Anything (SAM, 2023)
  - 11 milyon görüntü, 1 milyarı aşkın maske
  - Nokta, kutu ya da maske istemiyle bölütleme
- SAM 2 (2024): video bölütleme
- SAM 3 (2025): metinle tanımlanan kavramların bölütlenmesi
- Görevden bağımsız, sıfır örnekli kullanım
- Yeni görev için ince ayar ya da istem

Eğitim ve güncel yaklaşımlar

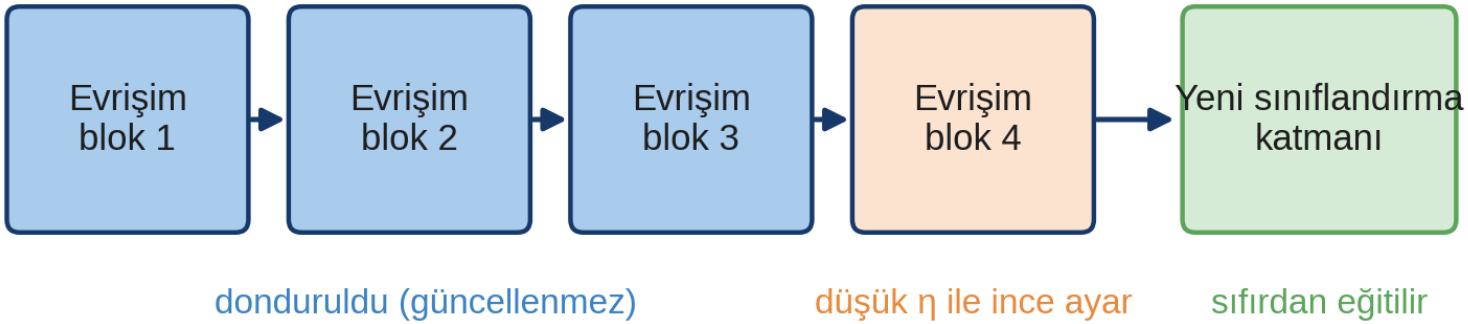
Veri artırma

- Etiketi değiştirmeyen dönüşümler
- Aşırı öğrenmeyi azaltır
- Geometrik: çevirme, kırpma, döndürme
- Fotometrik: parlaklık, renk
- Silme ve karıştırma: cutout, mixup, CutMix
- Dönüşüm göreve uygun olmalı



Transfer öğrenme

ImageNet üzerinde önceden eğitilmiş omurga



Az veri → yalnız baş
Orta veri → son bloklar
Çok veri → tüm ağ

Vision Transformer (ViT)

- Dosovitskiy vd. (2021)
- Görüntü sabit boyutlu yamalara bölünür (ör. 16 × 16)
- Her yama bir simge (token) gibi işlenir
- Konum gömmesi eklenir
- Transformer kodlayıcı + sınıflandırma başı



CNN mi, ViT mi?

- CNN: yerellik ve öteleme eşdeğerliği mimaride hazır
  - Az veride daha iyi genelleme
- ViT: bu önyargılar yok, veriden öğrenir
  - Çok büyük veri ya da öz-denetimli ön eğitimle üstün
- Hibrit yapılar: Swin Transformer, ConvNeXt
- Pratik: önceden eğitilmiş model ailesine göre seçim

Pratik öneriler – mimari

- Her katman kendi girdisi üzerinde doğrusal bir sınıflandırıcı gibi davranır
- Model derinleştirildikçe iyileşme garantisi yoktur
  - Artık bağlantı kullanılmalı
- Başlangıç değerleri: He başlatma
- Patlayan / kaybolan gradyanlar
  - Normalizasyon: batch normalization
  - Her durumda iyi sonuç garantisi yoktur

Pratik öneriler – verim

- Bir çekirdeğin çok kanallı özelliği tek fonksiyonda öğrenmesi maliyetli
- Derinlik ayrışımlı evrişim ile azaltma
  - Her kanala ayrı özellik çıkarımı
- Önce kanal genişletme, sonra derinlik yönlü evrişim
  - Ters artık blok (MobileNetV2)
- Girdi çözünürlüğü maliyeti karesel artırır