Derin Öğrenme

Diziler ve Tekrarlayan Sinir Ağları (RNN)

Hafta 4

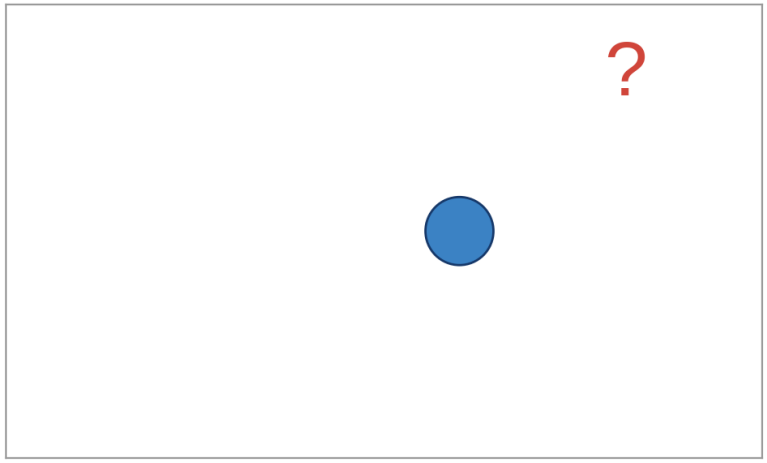
Doç. Dr. Emir Öztürk
Trakya Üniversitesi · Bilgisayar Mühendisliği

Dizi (sequence)

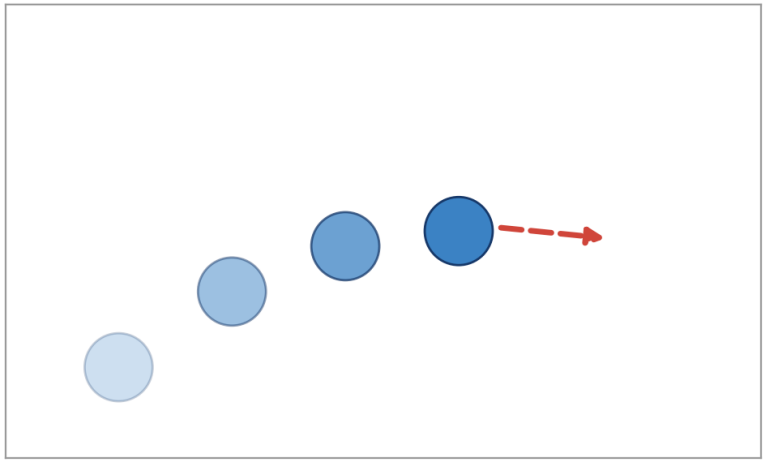
- Ardışık olarak gelen elemanlar
- Sıralama önemli
  - Cümlelerdeki kelime sırası
  - Videodaki kare sırası
  - Ses sinyali
  - Zaman serileri (sensör, finans, hava)
  - Karar algoritmalarındaki eylem sırası
- Diziler farklı uzunlukta olabilir

Dizinin tahmindeki etkisi

Tek kare: sonraki konum belirsiz



Dizi: hareket yönü tahmin edilebilir



Dizi için tam bağlı ağ ve CNN

- Tam bağlı ağ ve CNN sabit boyutlu girdi bekler
- Sıralama bilgisi doğrudan hesaba katılmaz
- Girdi uzunluğu değiştiğinde model değişmeli
- Farklı konumdaki aynı örüntü için ayrı ağırlıklar
- Eğitimde önemli ayrıntılar kaybolur

Sınıflandırmadan farkı

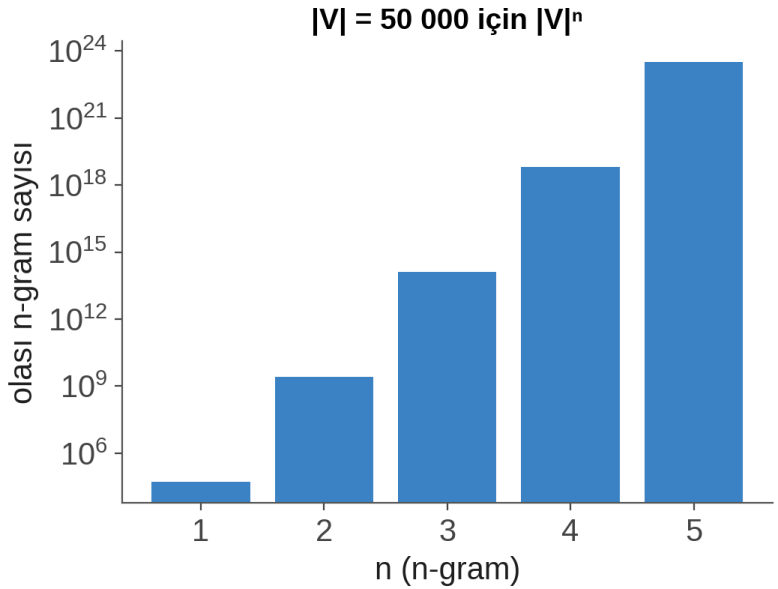
- Sınıflandırma: girdiye karşılık bir sınıf
- Dil modelleme: yalnız girdi dizisi bulunur
- Hedef, dizinin kendisinden türetilir
  - Sonraki elemanın olasılığı
- $P(w_1, \ldots, w_T) = \prod P(w_t \mid w_1, \ldots, w_{t-1})$
- Olasılığın en büyüklenmesi problemi

Doğal dilin modellenmesi: bağımsız olasılık

- Her kelimenin bağımsız olasılığının hesaplanması
- "The man sees the bird"
  - P(the) = %40, P(man) = %20, …
- En olası kelime seçilirse
  - The ____
  - The the ____
  - The the the ____
- Sıra bilgisi olmadan anlamlı üretim yapılamaz

N-gram modeli

- Bir kelimenin önceki n – 1 kelimeden sonra gelme olasılığı
  - Markov varsayımı
- Bağımsız olasılıktan daha başarılı
- Her bağlam için olasılık tablosu gerekir
- Tablo boyutu kelime sayısıyla üstel büyür
  - $|V|^n$ olası dizi



N-gram örneği: iki kelimelik bağlam

- "The man sees the man and the man sees the boy"

bağlam (2 kelime)	sonraki kelime (olasılık)
the man	sees (0,67), and (0,33)
man sees	the (1,0)
sees the	man (0,5), boy (0,5)
man and	the (1,0)
and the	man (1,0)

N-gram örneği: üç kelimelik bağlam

- Bağlam uzadıkça tahminler daha kesin
- Ancak tablo seyrekleşir

bağlam (3 kelime)	sonraki kelime (olasılık)
the man sees	the (1,0)
man sees the	man (0,5), boy (0,5)
sees the man	and (1,0)
the man and	the (1,0)
man and the	man (1,0)
and the man	sees (1,0)

Sadeleştirme ve sınırları

- Dahil edilen geçmiş kelime sayısını sınırlamak
  - Yer gereksinimi yeterince küçülmez
  - Bağlama ilişkin bilgi kaybolur
- Uzaktaki bir kelime son kelimeyi belirleyebilir
  - "**Öğrenciler** dün akşam hocalarıyla birlikte konferansa gittikleri için eve geç **döndüler**."
  - "The **keys** to the old wooden cabinet **are** on the table."

Olasılıkları öğrenmek

- Olasılık tablosu yerine
  - Olasılıkları üreten bir fonksiyon öğrenmek
- Bağlam ve sıra korunmalı
- Benzer bağlamlar benzer tahminler üretmeli
- Bunun için
  - Kelimelerin vektörleştirilmesi
  - Bağlamın bir durum vektöründe taşınması

Vektörleştirme: sözlük

- "The man sees the man and the man sees the boy"
- Sözlük çıkarımı
- Her kelimeye bir indis

Kelime	İndis
the	0
man	1
sees	2
and	3
boy	4

One-hot kodlama

- Vektör uzunluğu = sözlük boyutu
- Kelimenin indisindeki eleman 1, diğerleri 0
- man → [0 1 0 0 0]
- Tüm kelimeler birbirine eşit uzaklıkta
  - Anlam benzerliği ifade edilemez

Kelime	İndis	One-hot
the	0	1 0 0 0 0
man	1	0 1 0 0 0
sees	2	0 0 1 0 0
and	3	0 0 0 1 0
boy	4	0 0 0 0 1

Kelime torbası (bag of words)

- Kelimelerin geçme sayılarından bir vektör
- Sıra tutulmaz
- Aynı kelimelere sahip iki cümle farklı anlama gelebilir
  - "the dog bit the man" → {the: 2, dog: 1, bit: 1, man: 1}
  - "the man bit the dog" → {the: 2, dog: 1, bit: 1, man: 1}
- Metin sınıflandırmada hâlâ güçlü bir taban çizgisi

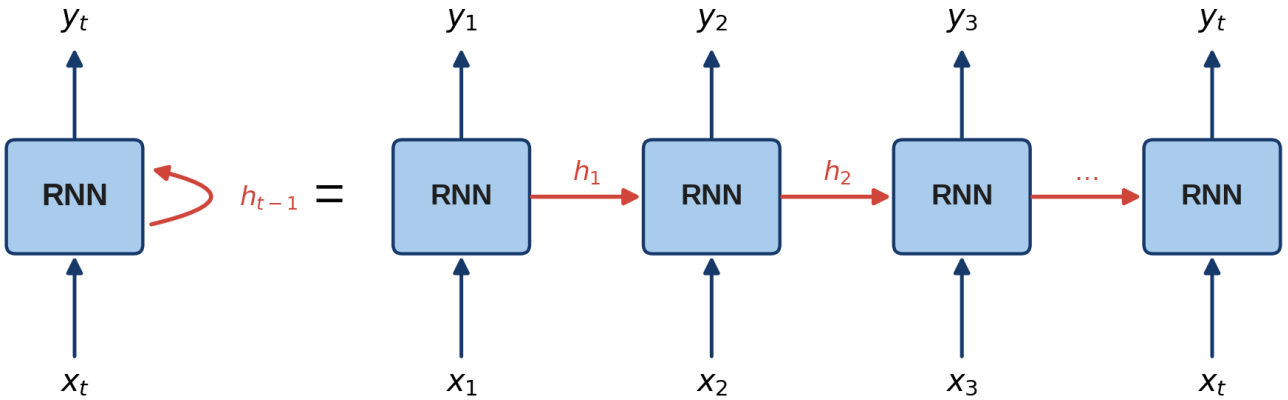
Dizi modelinden beklentiler

Gereksinim	Sabit pencere	Kelime torbası	RNN	LSTM / GRU	Transformer
Elemanların sırası korunmalı	✓	✗	✓	✓	✓
Farklı uzunlukta girdi	✗	✓	✓	✓	✓
Konumlar arası parametre paylaşımı	✗	–	✓	✓	✓
Yakın kelime grupları hesaba katılmalı	✓	✗	✓	✓	✓
Uzun dizilerde bağlam korunmalı	✗	✗	✗	~	✓

Tekrarlayan sinir ağları

RNN – Recurrent Neural Networks

- Her adımda gizli durum güncellenir
  - $h_t = \tanh(W_{hh} h_{t-1} + W_{xh} x_t + b)$
- Gizli durum geçmişin özetini taşır
- Aynı ağırlıklar tüm adımlarda paylaşılır
- Çıktı: tüm kelimeler için olasılık vektörü
  - $y_t = \text{softmax}(W_{hy} h_t)$, toplam 1



Aynı ağırlıklar (W_xh, W_hh, W_hy) her zaman adımında paylaşılır

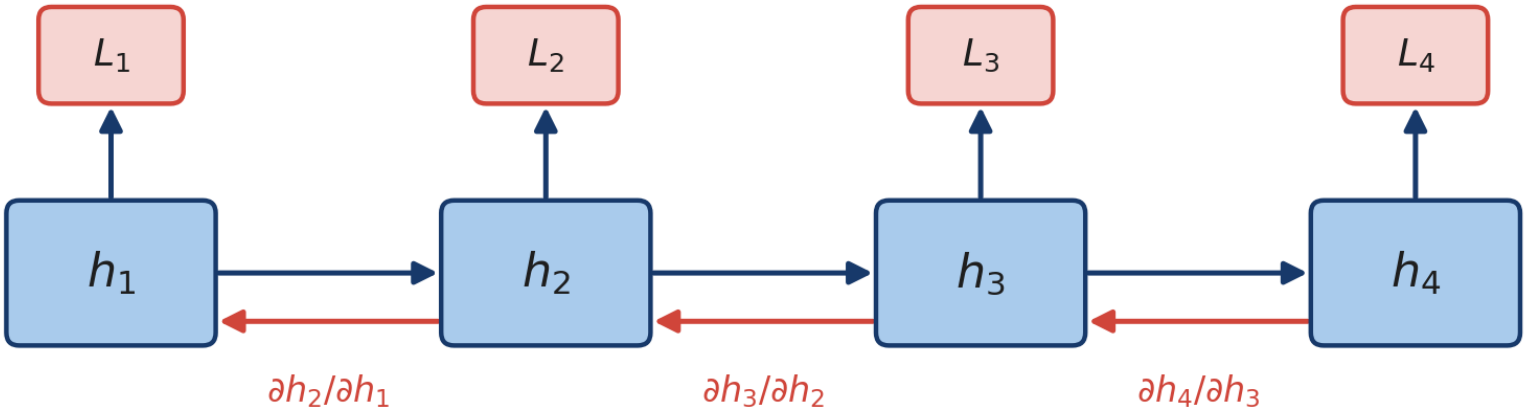
Eğitim verisinin hazırlanması

- Kayan pencere
  - Bir önceki pencerenin ilk kelimesi çıkarılır
  - Sonraki kelime eklenir
- "The man sees the man and the man sees the boy" (N = 5)
  - "the man sees the man" → and
  - "man sees the man and" → the
  - "sees the man and the" → man
  - "the man and the man" → sees
  - "man and the man sees" → the
  - "and the man sees the" → boy

Kayıp hesabı

- Girdi ve sıradaki doğru kelime biliniyor
- Model tüm kelimeler için olasılık üretiyor
- Her adımda çapraz entropi
  - $L_t = -\log P(\text{doğru kelime}_t)$
- Toplam kayıp: tüm adımların ortalaması
- Öğretmen zorlaması: eğitimde gerçek önceki kelime verilir

Zamanda geri yayılım (BPTT)

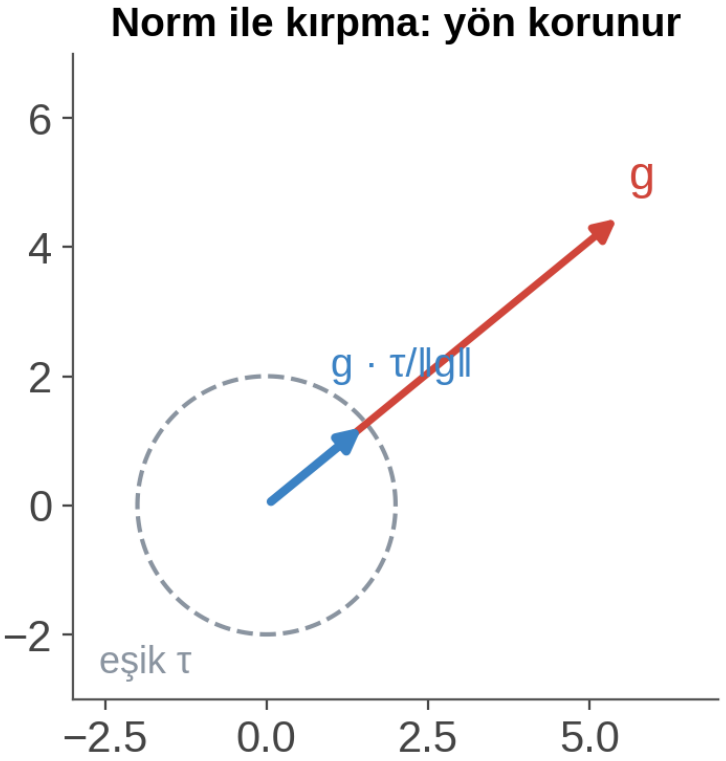


$$L = \sum_t L_t$$

Gradyan zaman içinde geriye taşınır: $\partial L_4/\partial h_1$ ifadesi $\prod_k \partial h_{k+1}/\partial h_k$ çarpımını içerir

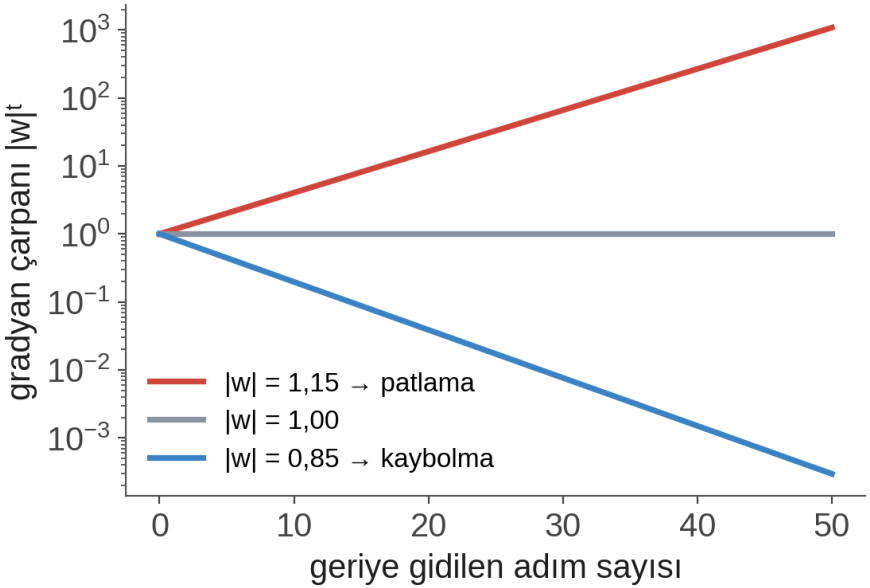
Patlayan gradyanlar (exploding gradients)

- Geri yayılımda aynı matris defalarca çarpılır
- En büyük özdeğer > 1 ise gradyan üstel büyür
- Belirtiler: kayıpta ani sıçramalar, NaN değerleri
- Çözüm: gradyan kırpma
  - ‖g‖ > τ ise g ← τ · g / ‖g‖



Kaybolan gradyanlar (vanishing gradients)

- Aynı mekanizma, özdeğer < 1
- Uzak adımların gradyanı sıfıra yaklaşır
- Model yalnız yakın geçmişten öğrenir
- tanh türevi ≤ 1 sorunu büyütür
- Azaltma yöntemleri
  - Kısaltılmış BPTT (daha az adım)
  - Uygun başlatma
  - Kapılı yapılar: LSTM, GRU

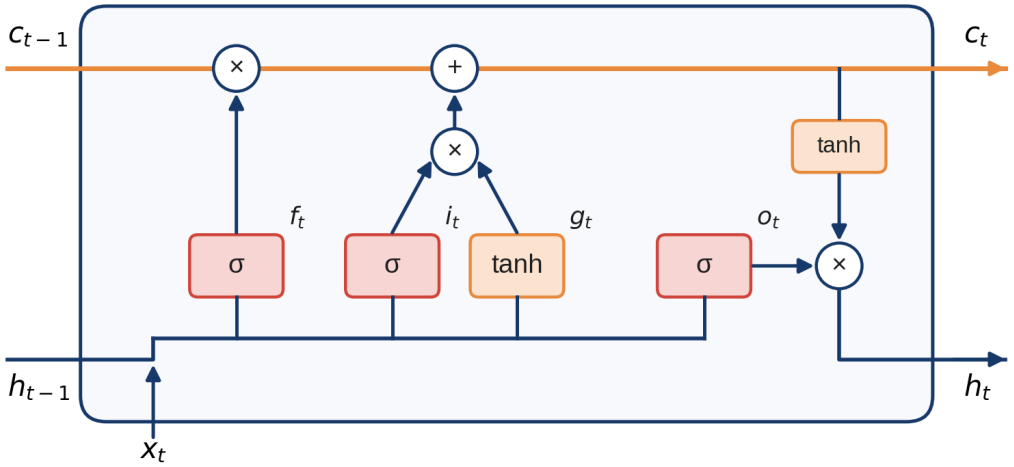


Uzun vadeli bağımlılıklar

- Belirli kelimeler cümleyi uzun vadede etkiler
- Bu bilgi kaybedilmemeli
- RNN'de bağlam teoride sınırsız, pratikte kısa
- Gradyan problemi nedeniyle
- Gereksinim: bilgiyi seçerek saklayan ve silen bir bellek

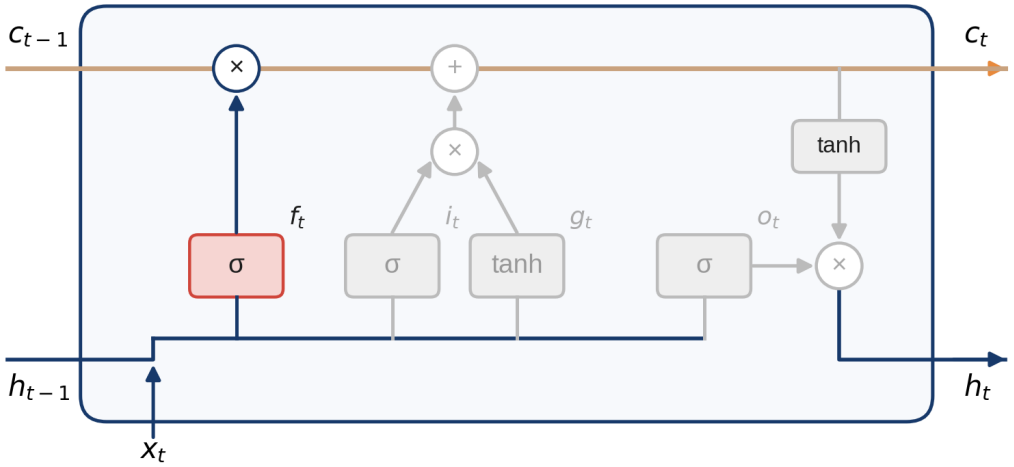
LSTM – Long Short-Term Memory

- Hochreiter, Schmidhuber (1997)
- Gizli duruma ek olarak hücre durumu c_t
- Kısa vade bilgisi: h_t
- Uzun vade bilgisi: c_t
- Bilgi akışını denetleyen üç kapı
  - Unutma, girdi, çıktı



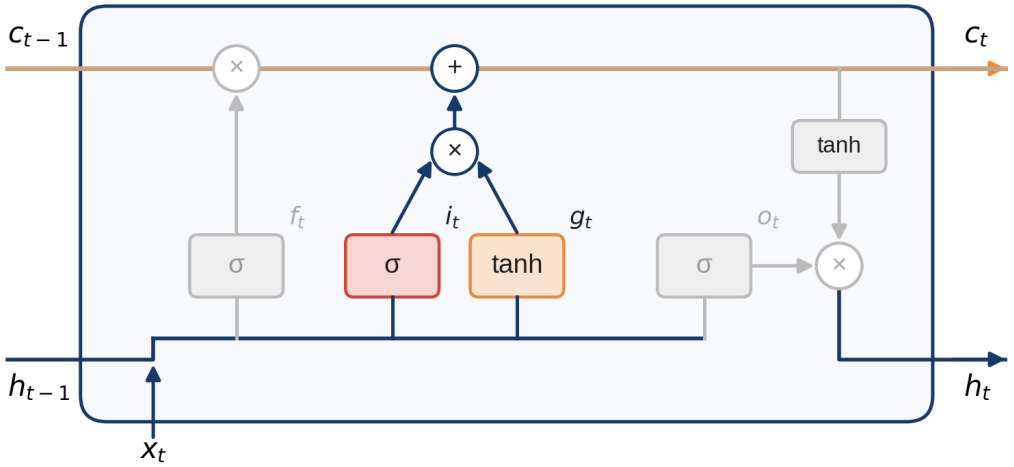
Unutma kapısı (forget gate)

- Bazı bilgilerin unutulması gerekir
  - Yeni bir cümleye geçildiğinde özne değişir
- $f_t = \sigma(W_f [h_{t-1}, x_t] + b_f)$
- c_{t-1} ile eleman bazında çarpılır
  - 0: tamamen sil, 1: tamamen koru



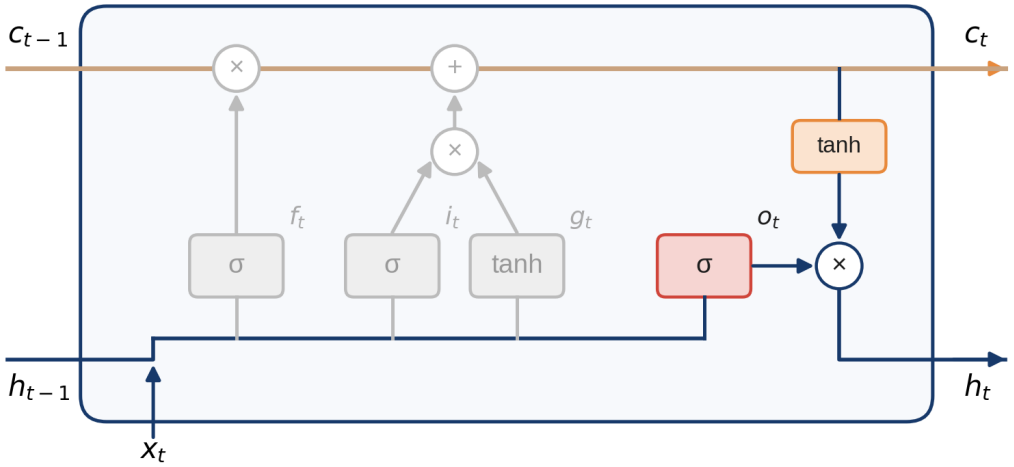
Girdi kapısı (input gate)

- Hücre durumuna eklenecek yeni bilgi
- Aday değer: $g_t = \tanh(W_g [h_{t-1}, x_t] + b_g)$
- Girdi kapısı: $i_t = \sigma(W_i [h_{t-1}, x_t] + b_i)$
- Güncelleme: $c_t = f_t \odot c_{t-1} + i_t \odot g_t$



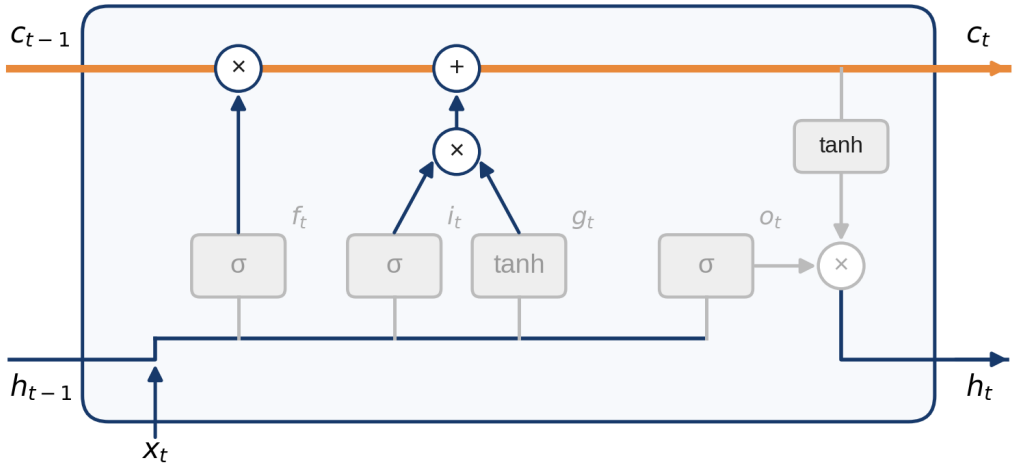
Çıktı kapısı (output gate)

- Hücre durumunun hangi kısmı dışarı verilecek
- $o_t = \sigma(W_o\ [h_{t-1}, x_t] + b_o)$
- $h_t = o_t \odot \tanh(c_t)$
- h_t: bu adımın çıktısı ve sonraki adımın girdisi



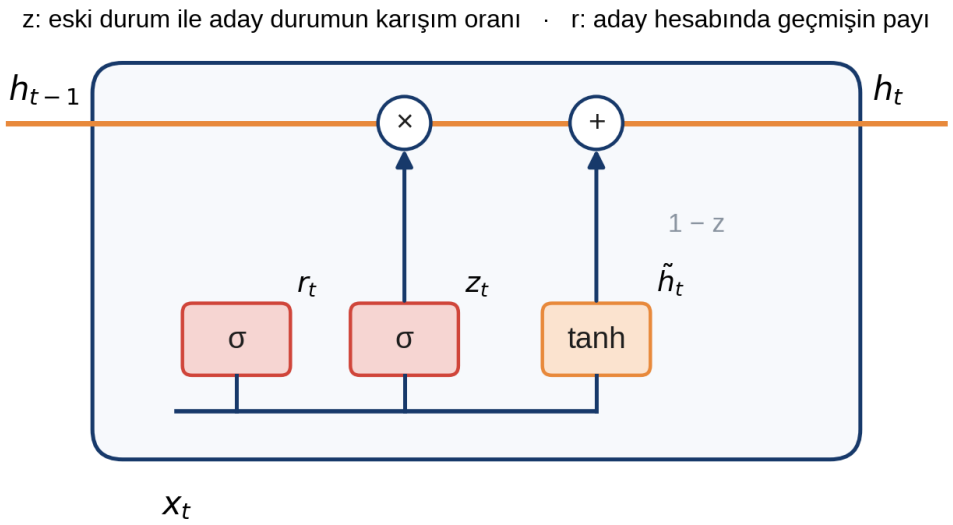
Gradyan neden korunur?

- Hücre durumu toplama ile güncellenir
  - $\partial c_t / \partial c_{t-1} = f_t$
- $f_t \approx 1$ olduğunda gradyan kayıpsız taşınır
- ResNet'teki artık bağlantı ile aynı fikir
- Parametre sayısı: RNN'in yaklaşık 4 katı



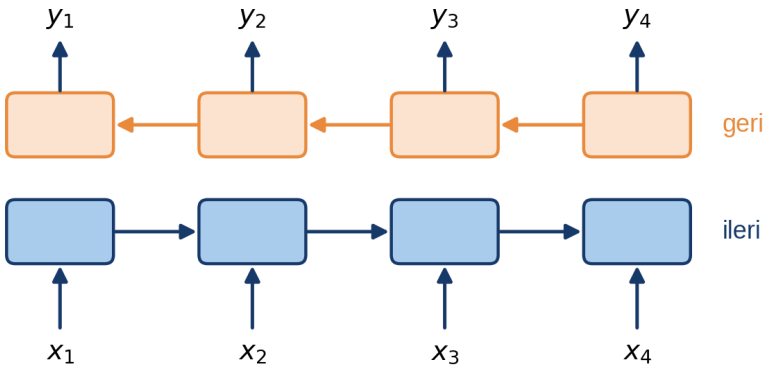
GRU – Gated Recurrent Unit

- Cho vd. (2014)
- Hücre ve gizli durum birleştirilmiş
- İki kapı
  - Güncelleme kapısı z_t
  - Sıfırlama kapısı r_t
- $h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$
- LSTM'e göre daha az parametre, benzer başarı



Çift yönlü ve çok katmanlı RNN

- Çift yönlü RNN
  - Dizi iki yönde işlenir
  - Her konumda geçmiş ve gelecek bilgisi
  - Etiketleme, sınıflandırma (üretimde kullanılamaz)
- Çok katmanlı (yığılmış) RNN
  - Bir katmanın gizli durumları üst katmanın girdisi



Diziden diziye modeller

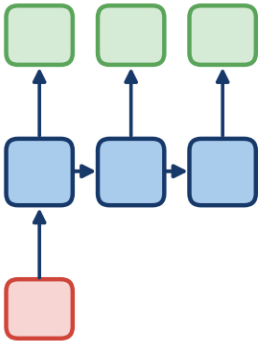
Dizi görev türleri

Bire bir



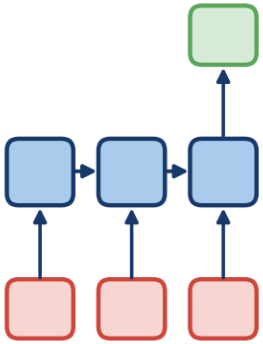
görüntü sınıflandırma

Bire çok



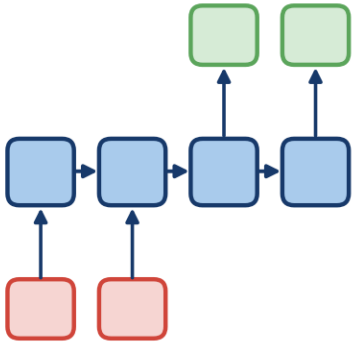
metin üretimi,
görüntü altyazısı

Çoka bir



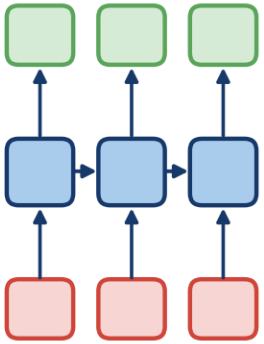
duygu analizi

Çoka çok (gecikmeli)



makine çevirisi

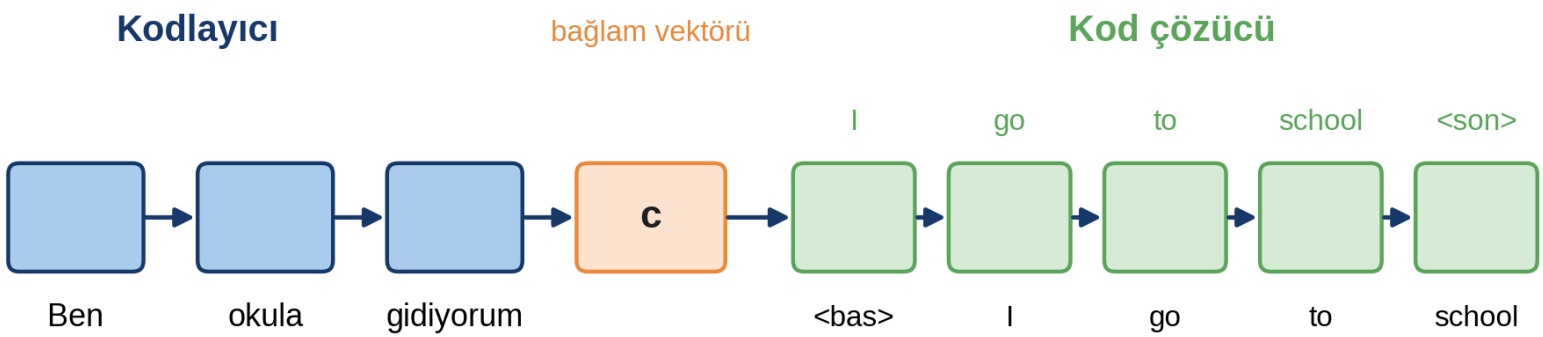
Çoka çok (eş zamanlı)



kelime türü etiketleme

Diziden diziye (seq2seq) modeller

- Sutskever vd. (2014), Cho vd. (2014)
- Kodlayıcı: girdi dizisini oku
- Bağlam vektörü: son gizli durum
- Kod çözücü: çıktı dizisini adım adım üretir
- Girdi ve çıktı uzunlukları farklı olabilir



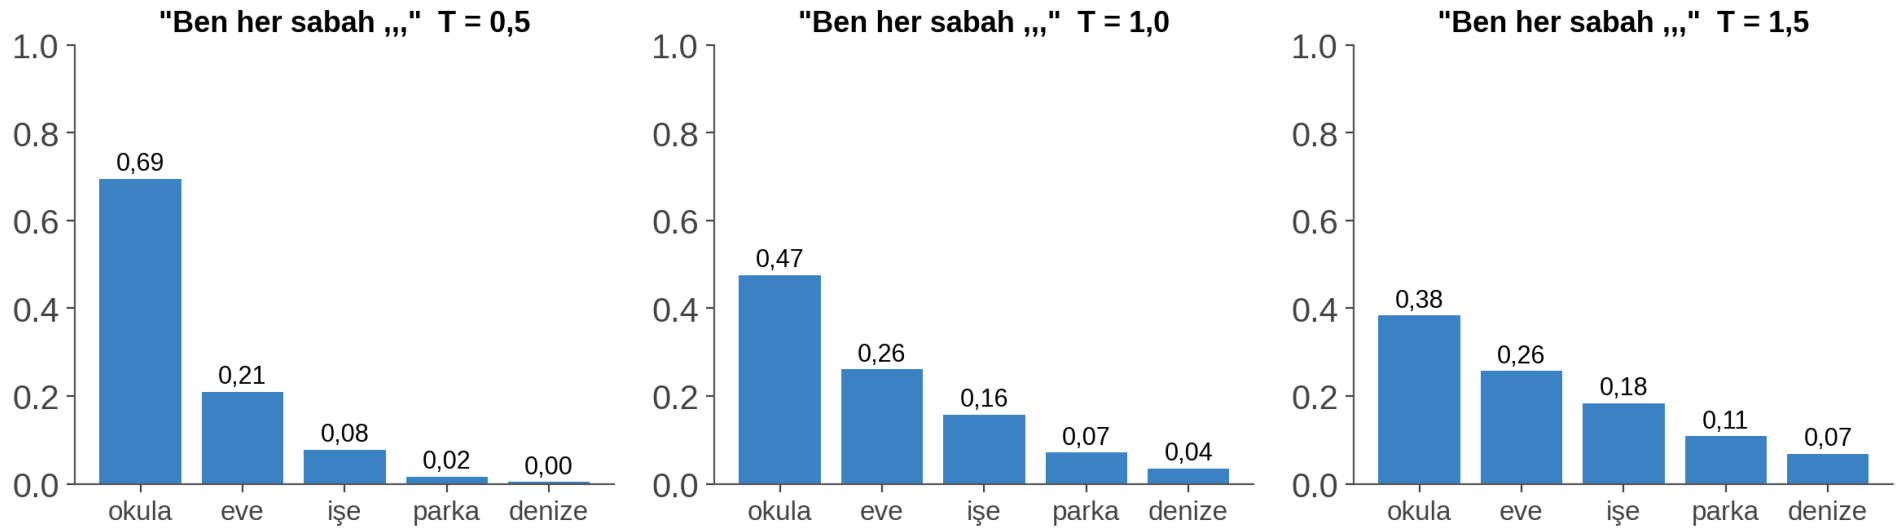
Tüm kaynak cümle tek bir sabit boyutlu vektöre sıkıştırılır → uzun cümlelerde darboğaz

Diziden diziye: diğer veri türleri

- Görüntü de bir dizi olarak düşünülebilir
- Dil → dil yerine dil → görüntü, görüntü → dil
  - Görüntü altyazısı (CNN kodlayıcı + RNN kod çözücü)
- Ses de bir dizidir
  - Konuşma tanıma: ses → metin
  - Konuşma sentezi: metin → ses
- Günümüzde bu görevlerin çoğunda Transformer

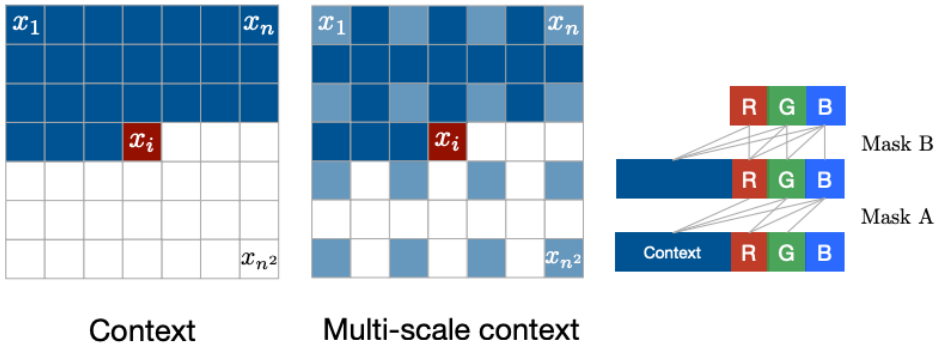
Üretim (generation)

- Otoregresif üretim
  - Önceki adımın çıktısı sonraki adımın girdisi
- Kod çözme stratejileri
  - Açgözlü: en olası kelime
  - Işın araması (beam search)
  - Örnekleme: sıcaklık, top-k, top-p



PixelRNN

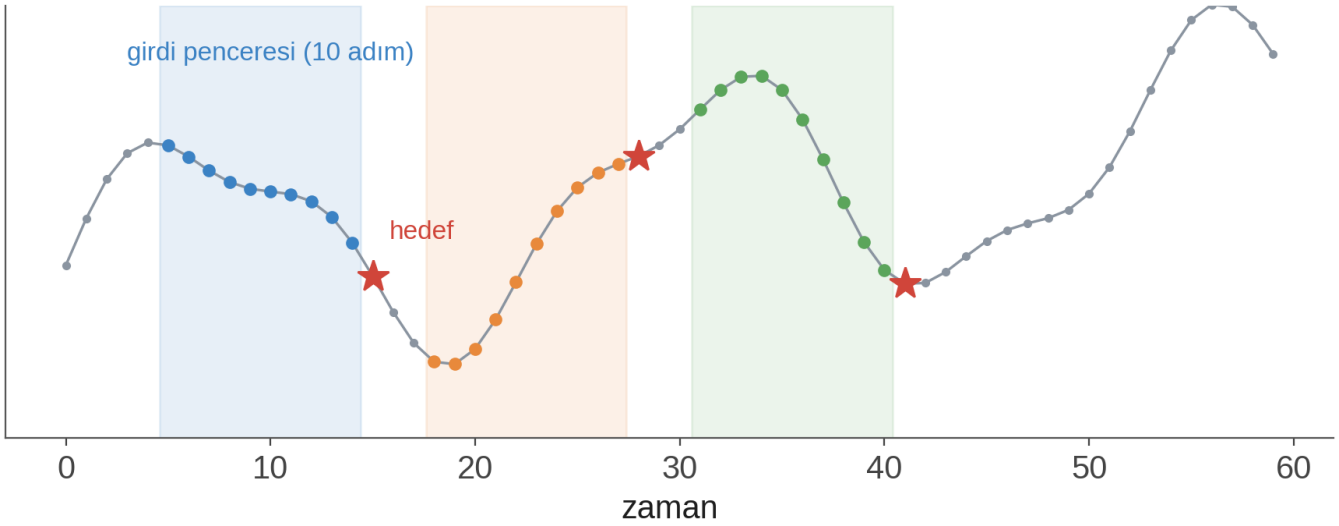
- van den Oord vd. (2016)
- Görüntü piksel piksel bir dizi olarak üretilir
- Her piksel önceki piksellere koşullu
- Tamamlama: görüntünün eksik kısmının üretilmesi





Zaman serisi tahmini

- Sensör, enerji, trafik, finans verileri
- Kayan pencere ile girdi–hedef çiftleri
- Tek adım ya da çok adım ileri tahmin
- Zamana göre bölme: gelecekten sızıntı olmamalı
- Güçlü taban çizgileri: son değer, mevsimsel ortalama



Tekrarlayan modellerin güncel durumu

- Transformer: paralel eğitim, uzun bağlam
  - Ancak dizi uzunluğuna göre karesel maliyet
- Tekrarlayan fikrin geri dönüşü
  - Durum uzayı modelleri: S4, Mamba
  - xLSTM (2024), RWKV
- Doğrusal zamanlı çıkarım, sabit bellek
- Ayrıntılar: 12. hafta